

MCDI503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

AVANCE DEL PROYECTO FASE 1

Nombre integrante/s: Arturo Knopke Vera, Nicolás Soletic Cobos, Sebastián Navarrete Soto, Roberto Moncada González

Curso: MCDI503 – Exploración Inteligente para la Ciencia de Datos

Fecha: 6 de septiembre de 2026

Título del avance: Análisis exploratorio reproducible del dataset Titanic — Fase 1

Docente responsable: Sergio Paraíso Medina

INDICE

- I. Portada e Índice.
- II. Introducción y contextualización.
- III. Objetivo exploratorio, preguntas iniciales y alcance del avance
- IV. Implementación inicial del EDA en notebook.
- V. Documentación trazable de decisiones exploratorias.
- VI. Reproducibilidad y coherencia técnica
- VII. Registro del proceso, supuestos y limitaciones
- VIII. Hallazgos exploratorios iniciales y referencias al notebook
- IX. Bibliografía

II. Introducción y contextualización

El hundimiento del RMS Titanic el 15 de abril de 1912, durante su viaje inaugural, es uno de los naufragios más documentados de la historia moderna: de las 2224 personas a bordo murieron 1502 (Kaggle, s. f.), en gran medida por la insuficiencia de botes salvavidas. Si bien el azar tuvo un papel en la supervivencia, la evidencia histórica sugiere que ciertos grupos de pasajeros —según sexo, clase de pasaje o edad— tuvieron mayores probabilidades de sobrevivir que otros.

El proyecto trabaja con el dataset Titanic-Dataset.csv (891 pasajeros, 12 variables), que combina información demográfica, socioeconómica (clase de pasaje, tarifa) y de composición familiar a bordo. Este avance de Fase 1 tiene como propósito consolidar un primer ciclo de análisis exploratorio de datos (EDA) reproducible, que sirva de base técnica coherente para el desarrollo de fases posteriores del proyecto, entre ellas la eventual estimación de la probabilidad de supervivencia de un pasajero. El valor esperado del análisis es doble: por un lado, diagnosticar la calidad de los datos disponibles; por otro, identificar señales preliminares de asociación entre las variables registradas y la supervivencia, que orienten decisiones de modelado en etapas siguientes.

III. Objetivo exploratorio, preguntas iniciales y alcance del avance

Objetivo exploratorio: implementar un primer ciclo de EDA reproducible sobre el dataset Titanic que permita caracterizar la estructura y calidad del conjunto de datos, identificar patrones preliminares de asociación con la supervivencia, y documentar de forma trazable las decisiones, supuestos y limitaciones.

Preguntas exploratorias iniciales:

- ¿Cuál es la estructura general del dataset (dimensiones, tipos de variables, completitud)?
- ¿Cómo se distribuye la tasa de supervivencia global y según variables categóricas clave (sexo, clase de pasaje, puerto de embarque)?
- ¿Existen diferencias en variables numéricas (edad, tarifa, tamaño familiar) entre sobrevivientes y no sobrevivientes?
- ¿Qué variables presentan valores faltantes relevantes y cómo deberían tratarse en esta primera etapa?
- ¿Se observan valores atípicos evidentes en variables numéricas continuas como Fare y Age?

Alcance del avance: se cubre la carga y revisión inicial del dataset, la exploración descriptiva univariada y bivariada, la construcción de variables derivadas (tamaño familiar, indicador de viajar solo, título extraído del nombre, indicador de cabina registrada) y la síntesis de hallazgos iniciales. No se realiza en esta fase imputación definitiva de valores faltantes, codificación final de variables ni modelado predictivo.

Supuestos iniciales y limitaciones preliminares: el dataset corresponde a un subconjunto de 891 pasajeros y no representa la totalidad de personas a bordo; la ausencia de Age podría asociarse a variables observadas como Pclass, y los 2 casos faltantes de Embarked se tratan de forma puntual. Como limitación preliminar, Cabin presenta demasiados valores faltantes (~77%) para su uso directo.

IV. Implementación inicial del EDA en notebook

El notebook mcdi503_f1_sumativo_grupo5.ipynb implementa el flujo descrito en 8 apartados: (I) Identificación del proyecto, (II) Contexto y objetivo exploratorio, (III) Carga y revisión inicial de datos, (IV) Exploración preliminar, (V) Decisiones y transformaciones iniciales, (VI) Resultados e interpretación inicial, (VII) Supuestos y limitaciones, (VIII) Cierre del avance. Cada apartado combina celdas narrativas en Markdown (contexto, justificación e interpretación) con celdas de código ejecutables (carga de datos, cálculos y visualizaciones implementados con pandas y seaborn; McKinney, 2010; The pandas development team, 2026; Waskom, 2021), de modo que el razonamiento y la evidencia computacional queden integrados en una misma secuencia legible.

Cada pregunta exploratoria planteada en el apartado III de este informe se responde con una acción concreta en el notebook: la estructura y completitud del dataset se aborda en el apartado III del notebook (carga y revisión inicial); el diagnóstico y tratamiento inicial de valores faltantes en los apartados III y V; las distribuciones univariadas y frecuencias categóricas en el apartado IV (exploración preliminar); las diferencias entre grupos y la detección de outliers en el apartado VI (resultados e interpretación inicial), apoyado en las variables derivadas del apartado V (decisiones y transformaciones iniciales).

V. Documentación trazable de decisiones exploratorias

En el apartado V del notebook se registran cinco decisiones exploratorias, cada una con su justificación y el resultado intermedio que produjo:

- **Cabin** — con 77,1% de valores faltantes, no se imputa; se crea el indicador binario Cabin_registrada, porque la sola presencia del dato puede ser informativa.
- **Age** — con 19,9% de valores faltantes, se mantiene sin imputar en esta fase; se crea Age_registrada y se calcula, solo con fines diagnósticos, la mediana de edad por Pclass (37 años en 1ª clase, 29 en 2ª, 24 en 3ª) y se verifica que la proporción de faltantes difiere por clase (13,9% / 6,0% / 27,7%), lo que sugiere asociación con Pclass.
- **Embarked** — solo 2 casos faltantes (0,22%); se imputan con la moda ('S'), generando Embarked_imputado, dado el impacto marginal sobre la muestra.
- **FamilySize / IsAlone** — se combinan SibSp y Parch en FamilySize = SibSp + Parch + 1, y se deriva IsAlone, para observar el efecto del tamaño del grupo familiar sobre la supervivencia.
- **Title** — se extrae el tratamiento (Mr., Mrs., Miss., Master., etc.) desde Name mediante expresión regular, agrupando categorías poco frecuentes en 'Other', para condensar información demográfica y de estatus.

Estas decisiones y sus resultados intermedios (tabla de medianas por clase, distribución de títulos, vista del dataset ampliado) se documentan en el apartado V del notebook, y su efecto sobre la exploración se retoma explícitamente en el apartado VI.

VI. Reproducibilidad y coherencia técnica

El notebook se ejecutó de principio a fin sin errores (jupyter nbconvert --execute), en orden secuencial de celdas, sin dependencias externas a los archivos del repositorio ni pasos manuales fuera del propio notebook. Los datos de entrada (data/Titanic-Dataset.csv) se cargan una única vez en el apartado III y todas las transformaciones posteriores (apartado V) se aplican sobre una copia explícita (titanic_exp), preservando el dataframe original para trazabilidad. Los resultados presentados en los apartados IV y VI del notebook son reproducibles directamente a partir de esa cadena de transformaciones, sin valores 'hardcodeados' que no puedan regenerarse desde el código.

Criterios básicos de organización aplicados, en línea con las prácticas de reproducibilidad del curso (Paraíso, 2026; Wilson et al., 2017): importación única de librerías y configuración fija de estilo gráfico (sns.set_theme) al inicio, rutas relativas (../data, ../figures) para portabilidad del proyecto, y persistencia de las figuras generadas en figures/ con nombres identificables (f1_titanic_*.png), lo que permite verificar cada resultado gráfico citado en este informe contra su salida original en el notebook.

VII. Registro del proceso, supuestos y limitaciones

Pasos principales seguidos durante la exploración: carga del dataset y revisión de dimensiones, tipos de datos y valores faltantes (apartado III); estadísticas descriptivas y visualizaciones univariadas de variables numéricas y categóricas (apartado IV); documentación de cinco decisiones exploratorias y variables derivadas (apartado V); análisis bivariado frente a Survived, detección de outliers con IQR y matriz de correlación (apartado VI); síntesis de hallazgos y proyección (apartado VIII).

Supuestos considerados: el dataset no contiene duplicados relevantes (PassengerId es único) y refleja fielmente la información oficial disponible; la ausencia de Age podría estar asociada a variables observadas como Pclass; para Cabin no se evalúa el mecanismo de ausencia y su tratamiento se posterga por su elevada proporción de faltantes; ninguna se imputa de forma definitiva.

Limitaciones detectadas: Cabin es inutilizable de forma directa por su altísima tasa de valores faltantes (77,1%); solo se aprovechó como indicador binario; el 19,9% de valores faltantes en Age limita la robustez de los análisis que la involucran; no se realizaron pruebas estadísticas formales de asociación (p. ej., chi-cuadrado); las lecturas de esta fase son descriptivas, no inferenciales.

Alcances de esta primera implementación y aspectos pendientes para fases posteriores: definir la estrategia final de imputación de Age, decidir el tratamiento definitivo de Cabin, evaluar el tratamiento de outliers en Fare, y codificar variables y particionar los datos para el modelado predictivo.

VIII. Hallazgos exploratorios iniciales y referencias al notebook

- **Supervivencia global** — la tasa de supervivencia global es 38,4% (342 de 891 pasajeros). Véase notebook, apartado IV, conteo de Survived.
- **Sexo y clase de pasaje** — las mujeres sobrevivieron en 74,2% de los casos frente a 18,9% de los hombres; la supervivencia decrece con la clase de pasaje (1ª: 63,0%, 2ª: 47,3%, 3ª: 24,2%). Véase notebook, apartado VI, figura f1_titanic_supervivencia_categoricas.png.
- **Tarifa y correlaciones** — Fare se asocia positivamente con la supervivencia y Pclass negativamente, de forma consistente con el patrón anterior; entre las variables originales las correlaciones son moderadas o bajas, mientras que FamilySize correlaciona alto con SibSp (0,89) y Parch (0,78) por construcción, lo que condiciona su uso conjunto en el modelado. Véase notebook, apartado VI, figura f1_titanic_correlacion.png.
- **Composición familiar y título** — viajar acompañado (IsAlone = 0) se asocia a mayor supervivencia (50,6%) que viajar solo (30,4%); el título extraído del nombre reproduce con más matiz el patrón por sexo y clase. Véase notebook, apartado VI, figura f1_titanic_familia_titulo.png.
- **Valores atípicos** — Fare presenta 13,0% de valores atípicos (tarifas muy altas) y Age un 1,5%, detectados mediante la regla IQR; no se removieron en esta fase. Véase notebook, apartado VI, celda detectar_outliers_iqr y boxplots f1_titanic_boxplots_survived.png.

Interpretación breve: los hallazgos reproducen el patrón histórico conocido del hundimiento (prioridad de evacuación de mujeres, niños y pasajeros de clases altas) y sugieren que Pclass, Sex, Fare y las variables derivadas de composición familiar son candidatas relevantes para el modelado predictivo de fases posteriores, mientras que Age y Cabin requieren un tratamiento de datos faltantes más cuidadoso antes de incorporarse plenamente al análisis.

IX. Bibliografía

- Kaggle. (s. f.). *Titanic - Machine Learning from Disaster* [Conjunto de datos]. <https://www.kaggle.com/c/titanic>
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61. <https://doi.org/10.25080/Majora-92bf1922-00a>
- Paraíso, S. (2026). *Resumen aplicado del libro: EDA mínimo viable* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- The pandas development team. (2026). *pandas documentation* (versión 3.0) [Documentación de software]. <https://pandas.pydata.org/docs/>
- Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60),

3021. <https://doi.org/10.21105/joss.03021>

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>