



MCDI503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

Pipeline exploratorio reproducible de ingeniería de variables y selección preliminar de características del dataset Titanic — Cierre del proyecto, Fase 4

Curso	MCDI503 — Exploración inteligente para la ciencia de datos
Grupo	5
Integrantes	Arturo Knopke Vera, Nicolás Soletic Cobos, Sebastián Navarrete Soto, Roberto Moncada González
Docente	Sergio Paraíso Medina
Dataset	Titanic-Dataset.csv (Kaggle) integrado con seaborn-data, leídos desde sus repositorios públicos en GitHub; preparación de las Fases 2-3 reproducida en el notebook (891 × 32)
Notebook	mcDi503_f4_sumativo_grupo5.ipynb (ejecutado de principio a fin); salida: titanic_features.csv
Fecha	20 de septiembre de 2026

I. Título del avance y foco del pipeline final

Foco: cierre técnico del proyecto, cuya evidencia principal es el notebook de la Fase 4 (citado como «NB §»). Sobre la preparación de las Fases 2-3, el pipeline entrega un conjunto de características codificado, escalado y justificado para predecir la supervivencia de los pasajeros del RMS Titanic (Survived) en una etapa posterior de modelamiento.

II. Contexto del proyecto y objetivo del cierre

Contexto. El hundimiento del RMS Titanic (1912) es un caso clásico de clasificación binaria: la supervivencia se asocia a sexo, clase, edad y tamaño del grupo de viaje. Se mantuvo el dataset de las fases anteriores, la opción más completa para evidenciar transformaciones, variables derivadas, codificación y selección de características (Kaggle, s. f.).

Objetivo del cierre. Construir un pipeline reproducible que aplique transformaciones justificadas, derive un número acotado de variables con valor analítico explícito y seleccione características con criterios declarados, dejando el dataset listo para modelar sin entrenar ni evaluar un modelo predictivo en esta fase (RA4).

Relación con el análisis previo. Las Fases 2-3 dejaron imputados Age y Embarked, integrada la fuente seaborn-data y creadas Title_agrupado, FamilySize, AgeGroup, Fare_log y Deck_combinado. Dos hallazgos de ese EDA motivan la Fase 4: (i) el 13.02 % de Fare son atípicos por IQR y el 92.2 % de ellos comparte Ticket; (ii) el efecto de Pclass sobre la supervivencia difiere por sexo. El notebook lee ambas fuentes desde sus repositorios públicos, reproduce en memoria la preparación de las Fases 2-3 (NB §II.2) y construye el pipeline sobre ese resultado (NB §III).

III. Transformaciones y normalizaciones aplicadas

III.1 Diagnóstico de escala y asimetría (NB §IV.1)

Las Fases 2-3 ya corrigieron la asimetría de Fare (4.78 $\rightarrow$ 0.39 con log1p). Faltaba dejar las variables numéricas en una escala comparable para modelos sensibles a ella (regresión regularizada, KNN, SVM). La asimetría residual es alta en SibSp (3.69), Parch (2.74), FamilySize (2.72) y TicketGroupSize (2.22; NB §V.1), y moderada en Age_clean (0.53).

III.2 Transformaciones aplicadas (NB §IV.2 y §VIII)

Variables	Operación	Propósito y coherencia con el EDA	Efecto en los datos
Fare_per_person_log, FamilySize, TicketGroupSize	RobustScaler (mediana e IQR; sufijo _rs)	Colas de valores legítimos (grupos y familias numerosas). Mediana e IQR no se desplazan con la cola (FamilySize: media 1.90, mediana 1). Fare_per_person_log conserva 24 atípicos (2.7 %) vs. 116 de Fare (NB §IV.2, §VIII).	Mediana = 0 e IQR = 1; extremos conservados (FamilySize_rs máx. = 10.0).
Fare_per_person	log1p	Corrige la cola derecha de la tarifa por persona.	Asimetría 4.37 $\rightarrow$ 0.33.
Title_agrupado, Sex_Pclass, AgeGroup, Embarked_clean, Deck_combinado	Codificación <i>one-hot</i> con categoría de referencia (la más frecuente)	Los modelos requieren entradas numéricas; la categoría de referencia evita la colinealidad perfecta y hace interpretable cada coeficiente.	24 columnas indicadoras.

Tabla 1. Transformaciones y normalizaciones aplicadas en la Fase 4




Figura 1. Variables numéricas antes y después de RobustScaler

IV. Variables derivadas o creadas

Se crearon dos variables conceptuales, motivadas por hallazgos del EDA, que suman cuatro columnas nuevas (TicketGroupSize, Fare_per_person, Fare_per_person_log, Sex_Pclass), tres en el set final. Ninguna usa Survived ni variables posteriores al hundimiento (alive se excluye): sin fuga de información (NB §V.3).

Variable	Origen y regla	Hallazgo que la motiva y valor analítico
Fare_per_person_log (con TicketGroupSize)	Ticket y Fare. TicketGroupSize = pasajeros con el mismo Ticket;	134 tickets repetidos agrupan 344 pasajeros: Fare suele ser tarifa de grupo (separa «pagó más» de «viajó en grupo»).

Variable	Origen y regla	Hallazgo que la motiva y valor analítico
	Fare_per_person = Fare / TicketGroupSize; luego log1p (NB §V.1).	TicketGroupSize difiere de FamilySize en 32.3 %. Con Survived: Mann-Whitney (Mann & Whitney, 1947), $p = 6.3 \times 10^{-21}$, r rango-biserial = 0.373 (medianas 8.05 vs. 13.00).
Sex_Pclass	Concatenación de Sex y Pclass en una categórica de 6 niveles (NB §V.2).	Supervivencia femenina 96.8 % / 92.1 % / 50.0 % (1.ª/2.ª/3.ª clase) vs. masculina 36.9 % / 15.7 % / 13.5 %. V de Cramér (Cramér, 1946) = 0.627 (Sex 0.541; Pclass 0.340). Como cruzar variables siempre suma información, se probó la interacción con un test de razón de verosimilitudes contra el modelo aditivo (Wilks, 1938): LR = 28.79, $gl = 2$, $p = 5.6 \times 10^{-7}$.

Tabla 2. Variables derivadas, lógica de construcción y valor analítico

Matiz: controlando por el tamaño del grupo, el Spearman parcial de Fare_log con Survived cae 17.3 % y el de Fare_per_person_log solo 2.3 % (≈ 11 % ambas con residuos lineales). Como su asociación marginal no supera a la de Fare_log (0.373 frente a 0.384), se prefiere por interpretabilidad, no por mayor relevancia (NB §VI.2).


V. Selección preliminar de características

V.1 Criterios de selección (NB §VI)

(1) Relevancia frente a Survived (V de Cramér, rango-biserial e información mutua, *MI*, en nats; Kraskov et al., 2004), con V leída según Cohen (1988): 0.10 débil, 0.30 moderada, 0.50 fuerte; (2) redundancia, exacta (se elimina) o parcial (se conserva y documenta); (3) interpretabilidad; (4) consistencia: estabilidad del ranking de *MI* en 21 semillas (criterios según Kuhn & Johnson, 2019).

V.2 Decisiones y evidencia de relevancia

Decisión	Variables	Justificación
Priorizar	Sex_Pclass, Title_agrupado	Mayor relevancia ($V = 0.627$ y 0.570 , fuertes; <i>MI</i> 0.218 y 0.169). Title_agrupado distingue a los niños (Master); comparte con Sex_Pclass la información de sexo ($R^2 = 0.989$ al predecir Sex desde Title_agrupado), pero no de forma exacta.
Conservar	Fare_per_person_log, FamilySize, TicketGroupSize	Fare_per_person_log: asociación moderada (0.373), menos dependiente del grupo; reemplaza a Fare_log por interpretabilidad. FamilySize (0.173; $p = 8 \times 10^{-7}$) y TicketGroupSize (0.188; $p = 6 \times 10^{-8}$): débiles pero significativas y conceptos distintos (32.3 %).
Revisar	AgeGroup, Embarked_clean, Deck_combinado	AgeGroup ($V = 0.137$) y Embarked_clean ($V = 0.171$): asociación débil e <i>MI</i> marginal (0.009 y 0.014); se mantienen por sentido sustantivo; el puerto refleja en parte la clase (V con Pclass = 0.262). Deck_combinado: $V = 0.334$ (moderada), pero 27.8 % de celdas esperadas < 5 y 77.1 % «Desconocida» (no imputada).
Descartar	Pclass, Age_clean, Sex_bin, Fare_log, FareBand, IsAlone, Age_registrada, Cabin_registrada, class, who, adult_male, deck, embark_town, alone	Pclass: combinación lineal exacta de Sex_Pclass. IsAlone: función de FamilySize. Sex_bin: $V = 0.995$ con Title_agrupado. Fare_log, FareBand: redundantes con Fare_per_person_log. Age_clean: Mann-Whitney $p = 0.25$, pero su <i>MI</i> supera a la de AgeGroup; se descarta por imputación (19.9 %) e interpretabilidad (a revalidar). Age_registrada y Cabin_registrada: sin señal nueva. Las de seaborn-data coinciden con columnas propias (NB §VI.1).

Tabla 3. Decisiones de selección preliminar y justificación**Figura 2.** Información mutua (nats) de las variables candidatas frente a Survived (semilla 42)

El ranking es estable en 21 semillas: Sex_Pclass, Title_agrupado y Fare_per_person_log siempre encabezan, y AgeGroup y Embarked_clean cierran; solo varían las continuas (Fare_per_person_log: 0.092–0.122; Age_clean: 0.016–0.070). Como la *MI* mezcla dos estimadores no comparables, se lee como orden aproximado y no decide sola los descartes.

VI. Documentación reproducible del pipeline

VI.1 Registro y organización del notebook

El notebook está ejecutado de punta a punta; lee los datos desde sus fuentes públicas (Data Science Dojo, s. f.; Waskom, s. f.), verifica las versiones mínimas de requirements.txt antes de ejecutar (NB §II.1) y usa semilla fija (RANDOM_STATE = 42). Cada acción queda en una bitácora de 10 pasos (NB §VII), las decisiones en NB §VI.4 (cifras calculadas en el notebook) y el destino de las 36 columnas en NB §VI.5. Se usaron pandas (McKinney, 2010), SciPy (Virtanen et al., 2020), scikit-learn (Pedregosa et al., 2011), seaborn (Waskom, 2021) y la lógica de EDA mínimo viable del curso (Paraíso, 2026).

VI.2 Correspondencia entre los tres productos

Informe (PDF)	Notebook (NB)	Presentación (video)
II. Contexto y objetivo	I–III. Encabezado, carga y revisión	I–III. Problema, dataset y hallazgos
III–IV. Transformaciones y derivadas	IV–V. Transformaciones y derivadas	IV. Transformaciones y derivadas
V. Selección de características	VI. Selección preliminar	V. Selección preliminar
VI. Documentación	VII. Documentación y trazabilidad	Transversal
VII. Resultados	VIII. Resultado final del dataset	VI. Valor analítico del cierre
VIII. Decisiones y limitaciones	IX. Supuestos, limitaciones y cierre	VII. Limitaciones y cierre final

Tabla 4. Correspondencia entre informe, notebook y presentación

VII. Resultados del pipeline y valor analítico del cierre

Decisiones técnicas. Escalado robusto, dos variables derivadas validadas, eliminación de redundancias exactas y codificación *one-hot* con categoría de referencia (NB §VIII).

- **Mejoras en el dataset.** De 891×32 a 891×29 columnas (27 características más PassengerId y Survived): las 36 columnas disponibles tienen destino documentado (NB §VI.5): 14 se descartan según la Tabla 3 (12 por redundancia) y 4 se sustituyeron en las Fases 2-3 (Name, Age, Cabin, Embarked). Sin faltantes ni colinealidad exacta (rango completo, 28 de 28).

- **Valor para el modelamiento.** La señal dominante (sexo $\times$ clase, título, tarifa por persona) sugiere como referencia regresión logística regularizada o árboles; Sex_Pclass permite a un modelo lineal capturar el efecto no aditivo. PassengerId debe excluirse.
- **Valor para la comprensión del problema.** La tarifa observada mezcla precio y tamaño de grupo, y el efecto de la clase no es uniforme por sexo: en mujeres cae con fuerza solo en 3.ª clase; en hombres, ya desde la 2.ª (Tabla 2).

VIII. Decisiones metodológicas, supuestos y limitaciones

- **Decisiones.** Se reprodujo sin cambios la preparación de las Fases 2-3 sin entrenar un modelo predictivo; la interacción Sex_Pclass se validó con un test formal, la *MI* con una prueba de estabilidad y la redundancia con un criterio único (exacta: se elimina; parcial: se documenta).
- **Supuestos.** Los 15 registros con Fare = 0 (todos varones) se asumen tarifa legítima y se conservan. Los criterios bastan para una selección preliminar, a revalidar con un modelo (en particular el descarte de Age_clean). La ejecución requiere conexión a internet y que las URL de origen se mantengan disponibles y sin cambios.
- **Limitaciones.** Deck_combinado es 77.1 % «Desconocida», con 27.8 % de celdas esperadas < 5; persiste redundancia parcial entre Title_agrupado y Sex_Pclass; la evidencia es univariada y con 891 casos los subgrupos son frágiles. El RobustScaler se ajustó con todos los registros: al modelar deberá ajustarse solo con el entrenamiento.

IX. Bibliografía

- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.
- Cramér, H. (1946). *Mathematical methods of statistics*. Princeton University Press.
- Data Science Dojo. (s. f.). *datasets* [Repositorio de datos]. GitHub. <https://github.com/datasciencedojo/datasets>
- Kaggle. (s. f.). *Titanic - Machine learning from disaster* [Conjunto de datos]. <https://www.kaggle.com/c/titanic>
- Kraskov, A., Stögbauer, H., & Grassberger, P. (2004). Estimating mutual information. *Physical Review E*, 69(6), Artículo 066138. <https://doi.org/10.1103/PhysRevE.69.066138>
- Kuhn, M., & Johnson, K. (2019). *Feature engineering and selection: A practical approach for predictive models*. CRC Press.
- Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1), 50–60. <https://doi.org/10.1214/aoms/1177730491>
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61. <https://doi.org/10.25080/Majora-92bf1922-00a>
- Paraíso, S. (2026). *Resumen aplicado del libro: EDA mínimo viable* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272. <https://doi.org/10.1038/s41592-019-0686-2>
- Waskom, M. L. (s. f.). *seaborn-data* [Repositorio de datos]. GitHub. <https://github.com/mwaskom/seaborn-data>
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), Artículo 3021. <https://doi.org/10.21105/joss.03021>
- Wilks, S. S. (1938). The large-sample distribution of the likelihood ratio for testing composite hypotheses. *The Annals of Mathematical Statistics*, 9(1), 60–62. <https://doi.org/10.1214/aoms/1177732360>