

Diagnóstico, limpieza, integración y análisis exploratorio univariado-bivariado del dataset Titanic — Avance del Proyecto, Fases 2 y 3

Curso	MCDI503 — Exploración inteligente para la ciencia de datos
Grupo	5
Integrantes	Arturo Knopke Vera, Nicolás Soletic Cobos, Sebastián Navarrete Soto, Roberto Moncada González
Dataset principal	Titanic-Dataset.csv (891 registros, 12 variables) — Kaggle
Fuente complementaria	titanic (seaborn-data, mwaskom/seaborn-data) — origen web, usada para integración
Fecha	11 de septiembre de 2026

Foco del avance: este informe sintetiza el trabajo técnico documentado en el Jupyter Notebook *mcdi503_f23_sumativo_grupo5.ipynb*, que constituye la evidencia principal del proceso. El foco de análisis es la identificación de los factores asociados a la supervivencia de los pasajeros del RMS Titanic, a partir de un dataset preparado de forma trazable y reproducible.

II. Contexto del proyecto y descripción del conjunto de datos

El hundimiento del RMS Titanic (15 de abril de 1912) es uno de los naufragios más documentados de la historia moderna. Si bien la supervivencia tuvo un componente de azar, existe evidencia histórica de que factores como el sexo, la clase de pasaje y la edad influyeron en la probabilidad de sobrevivir. El proyecto busca caracterizar estos factores mediante un análisis exploratorio estadísticamente riguroso, como base para un eventual modelado predictivo en fases posteriores.

Fuente y unidad de análisis: la fuente principal es *Titanic-Dataset.csv* (Kaggle, *Titanic - Machine Learning from Disaster*), con 891 registros y 12 variables; la unidad de análisis es cada pasajero individual identificado por *PassengerId*. Para el ejercicio de integración exigido en esta fase se incorporó una **fuentes complementaria de origen web**: el dataset *titanic* del repositorio público *seaborn-data* (891 registros, 15 variables), que describe al mismo universo de pasajeros con variables adicionales (*class*, *who*, *adult_male*, *deck*, *embark_town*, *alone*).

Estructura general y variables relevantes: variables numéricas continuas (*Age*, *Fare*), discretas (*Pclass*, *SibSp*, *Parch*), la variable objetivo binaria *Survived*, y variables categóricas/texto (*Sex*, *Embarked*, *Name*, *Ticket*, *Cabin*). Para este avance, las variables priorizadas son *Survived* (objetivo), *Sex*, *Pclass*, *Age*, *Fare*, *Embarked* y las derivadas construidas en el proceso (*Title_agrupado*, *FamilySize*, *IsAlone*, *AgeGroup*, *Fare_log*, *Deck_combinado*).

III. Diagnóstico de calidad de datos realizado

Variable	Problema detectado	Magnitud
Cabin	Valores faltantes	687 casos (77.1%)
Age	Valores faltantes	177 casos (19.9%)
Embarked	Valores faltantes	2 casos (0.22%)
Fare	Valores en 0 (posible tarifa no estándar)	15 casos
Ticket	Valores repetidos (no es error; boletos grupales)	210 valores repetidos
PassengerId	Duplicados	0 casos (identificador único verificado)

No se detectan filas duplicadas ni inconsistencias de dominio (valores fuera de rango en *Sex*, *Embarked*, *Pclass*, *Survived* o edades inválidas). El campo crítico para la preparación posterior es *Age* (proporción relevante de faltantes) y, especialmente, *Cabin*: la proporción de camarote registrado decrece fuertemente desde primera hacia tercera clase (81.5% / 8.7% / 2.4%), asociación confirmada mediante una prueba chi-cuadrado formal (*Cabin_registrada* ~ *Pclass*, $p < 0.001$), evidencia de que su ausencia es **estructural (asociada a *Pclass*) y no aleatoria**, lo que descarta una imputación directa del valor específico.

IV. Limpieza, validación e integración de datos

Embarked: los 2 valores faltantes se imputaron de forma definitiva con la moda ("S"), dado su peso marginal (0.22%). **Age:** se imputó con la mediana estratificada por *Pclass* × *Sex* —no con una mediana global—; un test de Kruskal-Wallis confirma diferencias significativas de edad entre esos grupos ($H=112.28$; $p < 0.001$), lo que motiva la estratificación (una mediana global subestimaría/sobrestimaría la edad en varios subgrupos), aunque el test no mide directamente el error de imputación de una estrategia frente a la otra. Se conservó el indicador *Age_registrada* para no perder la señal de valor imputado. **Cabin:** no se imputa el camarote específico; se conserva únicamente un indicador de registro (*Cabin_registrada*).

Integración con la fuente web: dado que ninguna de las dos fuentes comparte un identificador explícito, la validez de la integración se estableció comprobando la coincidencia de siete variables conceptualmente equivalentes entre ambas fuentes (*Pclass*, *Sex*, *SibSp*, *Parch*, *Survived*, *Fare*, *Age*), obteniendo una coincidencia del **100%**, lo que confirma que ambas fuentes están alineadas registro a registro. Se incorporaron entonces las variables *class*, *who*, *adult_male*, *deck*, *embark_town*, *alone*, validando además su **coherencia semántica**: *Embarked* vs. *embark_town* y *Pclass* vs. *class* coinciden de forma perfecta y diagonal, y la primera letra de *Cabin* coincide en el 100% de los casos comparables con *deck*. La integración no resuelve el faltante de *Cabin/deck* (ambas fuentes comparten el mismo patrón de ausencia), pero sí aporta variables complementarias y validación cruzada.

V. Transformaciones aplicadas y preparación analítica del dataset

Se construyeron variables derivadas con sentido analítico explícito: *Sex_bin* (codificación binaria); *Title_agrupado*, extraído del nombre y consolidado en seis categorías interpretables (Mr 58.0%, Miss 20.8%, Mrs 14.1%, Master 4.5%, Oficial/Profesional 2.0%, Nobleza 0.6%); *FamilySize* e *IsAlone* (composición familiar); *AgeGroup* (rangos etarios demográficamente interpretables); *Fare_log* = $\log_{1p}(\text{Fare})$, que reduce la asimetría de 4.78 a 0.39; *FareBand* (cuartiles, lectura categórica robusta a la escala); y *Deck_combinado*, que aprovecha la integración de la sección IV para maximizar la información de cubierta disponible (aun así, 77.1% permanece "Desconocida"). Las variables nominales se tipificaron como *category*. El dataset preparado se exportó a *data/titanic_prepared.csv* para trazabilidad.

VI. Análisis univariado y bivariado desarrollado

Univariado: el test de normalidad de D'Agostino-Pearson rechaza la normalidad ($p < 0.05$) en *Age*, *Fare*, *Fare_log* y *FamilySize*, lo que justificó reportar mediana/IQR como medidas primarias. *Survived*: 38.4% de sobrevivientes (342/891); *Pclass*: 55.1% tercera clase; *Sex*: 64.8% hombres; *Embarked*: 72.5% Southampton.

Bivariado categórico (chi-cuadrado y V de Cramér frente a *Survived*):

Variable	χ^2	p-valor	V de Cramér	Lectura de efecto
Title_agrupado	289.84	<0.001	0.57	Fuerte
Sex	260.72	<0.001	0.54	Fuerte
Pclass	102.89	<0.001	0.34	Moderada
Deck_combinado	99.16	<0.001	0.33	Moderada*
IsAlone	36.00	<0.001	0.20	Débil-moderada
Embarked_clean	25.96	<0.001	0.17	Débil
AgeGroup	16.69	0.002	0.14	Débil

*Lectura de efecto según convención de Cohen (1988); los umbrales dependen de los grados de libertad (1 a 8 según la variable), por lo que la comparación directa entre variables es orientativa, no una escala única. Título_agrupado (16.7% de celdas con frecuencia esperada < 5) permanece dentro del umbral habitual de tolerancia (regla de Cochran: máx. 20%); Deck_combinado (27.8%) lo excede, por lo que su p-valor y su V deben interpretarse con mayor cautela.

Bivariado numérico (Mann-Whitney U frente a *Survived*, dada la no normalidad): *Fare* difiere significativamente (mediana 26.0 vs. 10.5; $p < 0.001$; $r \approx 0.38$, efecto moderado); *FamilySize* también difiere (mediana 2 vs. 1; $p < 0.001$; $r \approx 0.17$, efecto pequeño); *Age_clean* **no** muestra diferencia significativa ($p \approx 0.25$; $r \approx -0.05$). La correlación de Spearman entre *Survived* y *Fare* (0.32) es notoriamente mayor que la de Pearson (0.26), reflejo de la asimetría de *Fare*. El hallazgo más relevante es la **interacción Sex $\times$ Pclass**: la supervivencia femenina se mantiene alta en todas las clases (96.8% en 1ª, 92.1% en 2ª, 50.0% en 3ª), mientras que la masculina cae abruptamente (36.9%, 15.7%, 13.5%), matizando la heurística histórica de "mujeres y niños primero".

VII. Patrones, anomalías y hallazgos iniciales

La detección de outliers (IQR y Z-score robusto/MAD, del mismo orden de magnitud entre sí) identificó 116 casos atípicos en *Fare* (13.0%) y 33 en *Age_clean* (3.7%; estos últimos concentrados en su totalidad por encima de 57.75 años, sin ningún caso en el extremo bajo). El 90% de los outliers de *Fare* corresponde a primera clase y el 92.2% comparte número de *Ticket* con otro pasajero, evidencia correlacional consistente con **tarifas de boletos grupales/familiares** más que con errores sistemáticos de captura, aunque no permite descartar por completo algún caso puntual de error dentro de ese grupo. Los 15 casos con *Fare*=0 son, sin excepción, hombres embarcados en Southampton (14/15 con título "Mr"), varios con números de *Ticket* compartidos o atípicos (p. ej., 4 casos con *Ticket*="LINE"); el patrón es consistente con empleados de la naviera registrados como pasajeros, hipótesis razonable pero no verificable de forma concluyente con los campos disponibles.

VIII. Decisiones metodológicas, supuestos y limitaciones del avance

- La integración por posición (sin llave explícita) se validó empíricamente con 100% de coincidencia en siete variables compartidas; sigue siendo, en sentido estricto, un supuesto de alineación de orden.
- Se asume que la ausencia de Cabin/deck es MAR (asociada a *Pclass*) y no completamente al azar, con base en evidencia cruzada, sin poder descartar formalmente otros mecanismos.

- Las pruebas chi-cuadrado de Title_agrupado y Deck_combinado tienen categorías poco pobladas (celdas esperadas <5), lo que reduce la confiabilidad formal de esos p-valores específicos.
- La imputación de Age y el indicador Cabin_registrada implican riesgo de fuga de información si se reutilizan sin recalcular sobre el set de entrenamiento en una fase de modelado futura.
- El análisis es exploratorio y descriptivo: las asociaciones reportadas, incluida la interacción Sex × Pclass, no deben interpretarse como relaciones causales.

IX. Bibliografía

- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.^a ed.). Lawrence Erlbaum Associates.
- Kaggle. (s. f.). *Titanic - Machine Learning from Disaster* [Conjunto de datos]. <https://www.kaggle.com/c/titanic>
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56-61. <https://doi.org/10.25080/Majora-92bf1922-00a>
- Paraíso, S. (2026). *Resumen aplicado del libro: EDA mínimo viable* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- The pandas development team. (2026). *pandas documentation* (versión 3.0) [Documentación de software]. <https://pandas.pydata.org/docs/>
- Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261-272. <https://doi.org/10.1038/s41592-019-0686-2>
- Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
- Waskom, M. L. (s. f.). *seaborn-data* [Repositorio de datos]. GitHub. <https://github.com/mwaskom/seaborn-data>
- Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>