

MCDI503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

AVANCE DEL PROYECTO FASE 1

Nombre integrante/s:

Arturo Knopke Vera, Nicolás Soletic Cobos, Sebastián Navarrete Soto, Roberto Moncada González

Curso: MCDI503 – Exploración Inteligente para la Ciencia de Datos

Fecha: 6 de septiembre de 2026

Título del avance: Análisis exploratorio reproducible del dataset Titanic — Fase 1

Docente responsable: Sergio Paraíso Medina

Repositorio Github:

https://github.com/robertomoncada-blip/Magister_ciencia_datos/tree/main/MCDI503

INDICE

- I. Portada e Índice.
- II. Introducción y contextualización.
- III. Objetivo exploratorio, preguntas iniciales y alcance del avance
- IV. Implementación inicial del EDA en notebook.
- V. Documentación trazable de decisiones exploratorias.
- VI. Reproducibilidad y coherencia técnica
- VII. Registro del proceso, supuestos y limitaciones
- VIII. Hallazgos exploratorios iniciales y referencias al notebook
- IX. Bibliografía

II. Introducción y contextualización

El hundimiento del RMS Titanic (1912) es un naufragio ampliamente documentado: de 2.224 personas a bordo murieron 1502 (Kaggle, s. f.), por la falta de botes salvavidas, y la evidencia histórica sugiere que sexo, clase de pasaje y edad condicionaron la supervivencia. Se trabaja con Titanic-Dataset.csv (891 pasajeros, 12 variables): información demográfica, socioeconómica y de composición familiar. Este avance consolida un primer ciclo de análisis exploratorio de datos (EDA) reproducible como base de las fases posteriores, incluida la eventual estimación de supervivencia; su valor esperado es diagnosticar la calidad de los datos e identificar señales preliminares de asociación con la supervivencia que orienten el modelado.

III. Objetivo exploratorio, preguntas iniciales y alcance del avance

Objetivo exploratorio: implementar un primer ciclo de EDA reproducible sobre el dataset Titanic que permita caracterizar su estructura y calidad, identificar patrones preliminares de asociación con la supervivencia y documentar de forma trazable decisiones, supuestos y limitaciones. **Preguntas exploratorias iniciales:**

- ¿Cuál es la estructura general del dataset (dimensiones, tipos de variables, completitud)?
- ¿Cómo se distribuye la supervivencia global y según sexo, clase de pasaje y puerto de embarque?
- ¿Difieren edad, tarifa y tamaño familiar entre sobrevivientes y no sobrevivientes?
- ¿Qué variables presentan faltantes relevantes y cómo tratarlos en esta primera etapa?
- ¿Se observan valores atípicos evidentes en variables numéricas continuas como Fare y Age?

Alcance: carga y revisión, exploración univariada y bivariada, variables derivadas (tamaño familiar, viajar solo, título, cabina registrada) y síntesis; sin imputación definitiva, codificación ni modelado.

Supuestos iniciales y limitaciones preliminares: el dataset es un subconjunto de 891 pasajeros, no la totalidad de personas a bordo; la ausencia de Age podría asociarse a Pclass y los 2 faltantes de Embarked se tratan de forma puntual; Cabin tiene demasiados faltantes (~77%) para su uso directo.

IV. Implementación inicial del EDA en notebook

El notebook mcdi503_f1_sumativo_grupo5.ipynb se organiza en 8 apartados (identificación; contexto y objetivo; carga y revisión inicial; exploración preliminar; decisiones y transformaciones; resultados e interpretación; supuestos y limitaciones; cierre), cada uno con celdas narrativas en Markdown (contexto, justificación e interpretación) y celdas de código en pandas y seaborn (McKinney, 2010; The pandas development team, 2026; Waskom, 2021), integrando razonamiento y evidencia en una secuencia.

Cada pregunta del apartado III tiene una acción en el notebook: estructura y completitud (III); faltantes (III y V); distribuciones y frecuencias (IV); diferencias entre grupos y outliers (VI), con las variables derivadas de V.

V. Documentación trazable de decisiones exploratorias

El apartado V del notebook registra cinco decisiones, cada una con justificación y resultado intermedio:

- **Cabin** — 77,1% faltante: no se imputa; se crea Cabin_registrada, pues su presencia puede informar.
- **Age** — 19,9% faltante, sin imputar; se crea Age_registrada y, como diagnóstico, se calculan mediana de edad (37, 29 y 24 años) y proporción de faltantes (13,9% / 6,0% / 27,7%) por Pclass, lo que sugiere asociación.
- **Embarked** — 2 faltantes (0,22%), impacto marginal: imputados con la moda ('S') en Embarked_imputado.
- **FamilySize / IsAlone** — FamilySize = SibSp + Parch + 1 e IsAlone, para evaluar el efecto familiar.
- **Title** — tratamiento (Mr., Mrs., Miss., Master.) extraído de Name con expresión regular, agrupando los poco frecuentes en 'Other'; condensa información demográfica y de estatus.

Estos resultados intermedios quedan en el apartado V del notebook y se retoman en el VI.

VI. Reproducibilidad y coherencia técnica

Ejecutado sin errores (jupyter nbconvert --execute), en orden secuencial, sin dependencias externas; los datos (data/Titanic-Dataset.csv) se cargan una vez (III), las transformaciones (V) usan una copia (titanic_exp) que preserva el original y los de IV y VI se regeneran de esa cadena sin valores 'hardcodeados'.

Criterios de organización acordes con las prácticas de reproducibilidad (Paraíso, 2026; Wilson et al., 2017): importación única de librerías, estilo gráfico fijo (sns.set_theme), rutas relativas (../data, ../figures) y figuras persistidas en figures/ (f1_titanic_*.png), verificables en el notebook.

VII. Registro del proceso, supuestos y limitaciones

Pasos principales: carga y revisión (III); descriptivos univariados (IV); cinco decisiones y variables derivadas (V); bivariado frente a Survived, outliers IQR y correlación (VI); síntesis y proyección (VIII).

Supuestos considerados: PassengerId único y registros fieles; la ausencia de Age podría asociarse a Pclass; Cabin se posterga por su alta tasa de faltantes, sin evaluar el mecanismo; ninguna se imputa aún.

Limitaciones detectadas: Cabin (77,1% faltante) solo como indicador; el 19,9% faltante en Age limita sus análisis; sin pruebas estadísticas formales (p. ej., chi-cuadrado): lecturas descriptivas, no inferenciales.

Alcances y pendientes: imputación final de Age, tratamiento definitivo de Cabin y de los outliers de Fare, codificación y partición de datos para el modelado.

VIII. Hallazgos exploratorios iniciales y referencias al notebook

- **Supervivencia global** — 38,4% (342 de 891 pasajeros); notebook, apartado IV, conteo de Survived.
 - **Sexo y clase de pasaje** — mujeres 74,2% frente a hombres 18,9%; la supervivencia decrece con la clase (1ª 63,0%, 2ª 47,3%, 3ª 24,2%); notebook, apartado VI, f1_titanic_supervivencia_categoricas.png.
 - **Tarifa y correlaciones** — Fare correlaciona positivamente con Survived y Pclass negativamente; las demás correlaciones son moderadas o bajas, mientras FamilySize correlaciona alto con SibSp (0,89) y Parch (0,78) por construcción, condicionando su uso conjunto; notebook VI, f1_titanic_correlacion.png.
 - **Composición familiar y título** — acompañados (IsAlone = 0) sobreviven más (50,6%) que solos (30,4%); el título matiza el patrón por sexo y clase; notebook, apartado VI, f1_titanic_familia_titulo.png.
 - **Valores atípicos** — Fare presenta 13,0% de atípicos (tarifas altas) y Age 1,5%, según la regla IQR; no se removieron; notebook, apartado VI, celda detectar_outliers_iqr y f1_titanic_boxplots_survived.png.
- Interpretación: replican el patrón histórico (prioridad a mujeres, niños y 1ª clase) y sugieren que Pclass, Sex, Fare y la composición familiar son candidatas al modelado; Age y Cabin requieren tratar faltantes.

IX. Bibliografía

- Kaggle. (s. f.). *Titanic - Machine Learning from Disaster* [Conjunto de datos]. <https://www.kaggle.com/c/titanic>
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61. <https://doi.org/10.25080/Majora-92bf1922-00a>
- Paraíso, S. (2026). *Resumen aplicado del libro: EDA mínimo viable* [Apunte]. Universidad Andrés Bello.
- The pandas development team. (2026). *pandas documentation* [Documentación de software]. <https://pandas.pydata.org/docs/>
- Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
- Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>