

MCDI504

MACHINE LEARNING I

AVANCE DEL PROYECTO — FASE 2:

IMPLEMENTACIÓN DE MODELOS DE REGRESIÓN

SUPERVISADA

Predicción de la probabilidad de automatización de cargos hacia 2030 — Caso NextWork Advisory

Curso: MCDI504 - Machine Learning I

Docente: David Ruete

Grupo: 5

Integrantes:

- Arturo Knopke Vera
- Nicolás Soletic Cobos
- Sebastián Navarrete Soto
- Roberto Moncada González

Repositorio Github: [Magister_ciencia_datos/MCDI504 at main · robertomoncada-blip/Magister_ciencia_datos · GitHub](https://github.com/robertomoncada-blip/Magister_ciencia_datos/tree/main)

Fecha de entrega: 16 de agosto de 2026

Índice

- I. Portada e índice
- II. Introducción y contextualización
- III. Descripción del conjunto de datos y preprocesamiento
- IV. Modelo de regresión lineal multivariable
- V. Modelo de árboles de decisión para regresión
- VI. Modelo de redes neuronales para regresión
- VII. Evaluación de modelos de regresión
- VIII. Comparación de modelos
- IX. Notebook F2_Regresion.ipynb y documentación del proceso
- X. Conclusiones
- XI. Uso de fuentes, citación y referencias
- XII. Anexos

II. Introducción y contextualización

El presente informe corresponde al Avance del Proyecto — Fase 2: Implementación de modelos de regresión supervisada, del curso MCDI504 - Machine Learning I. En la Fase 1, el equipo definió el problema de negocio de **NextWork Advisory**, una consultora ficticia de estrategia de talento, que utiliza el dataset **AI Impact on Jobs 2030** para evaluar el riesgo de automatización de distintos cargos hacia el año 2030. Esa fase concluyó con la justificación de un enfoque de aprendizaje supervisado y dejó explícitamente planteada, como línea de análisis complementaria, la posibilidad de estimar directamente la variable continua *Automation_Probability_2030* mediante regresión supervisada, en lugar de la categoría discreta *Risk_Category*.

La Fase 2 retoma esa línea complementaria: el trabajo avanza desde la definición conceptual hacia la construcción de un pipeline analítico capaz de preparar los datos, entrenar modelos predictivos y evaluar sus resultados mediante métricas estadísticas. La actividad se sitúa en un problema de **regresión**, porque la variable objetivo que se desea predecir —*Automation_Probability_2030*— es continua, con valores entre 0 y 1.

El problema analítico consiste en estimar *Automation_Probability_2030* a partir de los predictores derivados del perfil laboral disponibles: *Average_Salary*, *Years_Experience*, *Education_Level* (codificada ordinalmente), *AI_Exposure_Index*, *Tech_Growth_Factor*, los diez puntajes de habilidades *Skill_1* a *Skill_10*, y el cargo (*Job_Title*). Como se detalla en la sección III, un análisis exploratorio realizado durante esta fase mostró que *Job_Title* concentra, por sí solo, cerca del 86% de la varianza de la variable objetivo, lo que motivó incorporarlo —mediante codificación one-hot— al conjunto final de predictores, revirtiendo una decisión de preprocesamiento inicial que lo excluía. Estos predictores representan características socioeconómicas, de trayectoria laboral y de perfil de competencias de cada cargo. La relación entre estas variables y la variable continua de salida permite aplicar modelos supervisados de regresión: regresión lineal, árboles de decisión y redes neuronales artificiales.

Desde la perspectiva metodológica, la fase busca generar evidencia técnica para la toma de decisiones de NextWork Advisory: no basta con entrenar modelos, sino que se deben interpretar sus resultados, contrastar sus métricas y justificar qué alternativa resulta más prometedora para continuar el proyecto. Esta lógica se sostiene en la evaluación integrada de MSE, RMSE y R^2 , que en conjunto permiten leer precisión, penalización de errores grandes y capacidad explicativa de cada modelo (Ruete, 2026d).



Flujo reproducible de la Fase 2: desde los datos hasta la comparación de modelos

Figura 1. Flujo de trabajo aplicado en la Fase 2 del proyecto.

III. Descripción del conjunto de datos y preprocesamiento

3.1 Descripción general del dataset

El conjunto de datos **AI Impact on Jobs 2030** contiene 3.000 observaciones (perfiles laborales simulados) y 18 columnas: el cargo (Job_Title, 20 categorías), variables numéricas de perfil (Average_Salary, Years_Experience), el nivel educativo (Education_Level, ordinal), dos índices de contexto (AI_Exposure_Index, Tech_Growth_Factor), diez puntajes de habilidades (Skill_1–Skill_10, escala 0-1) y dos variables de resultado relacionadas: Automation_Probability_2030 (continua, 0-1) y Risk_Category (categórica, derivada de la anterior por corte de umbrales). El dataset es el mismo utilizado en la Fase 1, lo que asegura coherencia entre ambas etapas del proyecto.

Variable	Rol	Descripción
Automation_Probability_2030	Objetivo (target)	Probabilidad continua (0-1) de automatización del cargo hacia 2030.
Average_Salary	Predictora	Salario promedio anual del cargo (USD).
Years_Experience	Predictora	Años de experiencia asociados al cargo.
Education_Level	Predictora (codificada ordinal)	Nivel educativo requerido: High School < Bachelor's < Master's < PhD.
AI_Exposure_Index	Predictora	Índice de exposición del cargo a tecnologías de IA (0-1).
Tech_Growth_Factor	Predictora	Factor de crecimiento tecnológico del sector asociado.
Skill_1 – Skill_10	Predictoras	Diez puntajes de dominio de habilidades (escala 0-1).
Job_Title	Predictora (codificada one-hot)	Cargo (20 categorías nominales); incorporada tras la exploración de la sección 3.3 (ver 3.4).
Risk_Category	Excluida en esta fase	Categoría de riesgo (Low/Medium/High); se excluye por derivarse del target (ver 3.4).

3.2 Evidencia de carga y revisión de valores faltantes

Tabla 1. Primeras cinco filas observadas en la carga del dataset AI Impact on Jobs 2030.

Job_Title	Average_Salary	Years_Experience	Education_Level	AI_Exposure_Index	Tech_Growth_Factor	Automation_Probability	Risk_Category
Security Guard	45.795	28	Master's	0.18	1.28	0.85	High
Research Scientist	133.355	20	PhD	0.62	1.11	0.05	Low
Construction Worker	146.216	2	High School	0.86	1.18	0.81	High
Software Engineer	136.530	13	PhD	0.39	0.68	0.34	Medium
Financial Analyst	70.397	22	High School	0.71	1.35	0.62	Medium

La revisión de valores nulos (df.isnull().sum()) entrega **cero valores faltantes en las 18 columnas del dataset**, confirmando el mismo diagnóstico obtenido en la Fase 1. Por tratarse de un dataset simulado y completo, no se requiere imputación ni eliminación de registros; el tratamiento de valores faltantes se limita a esta verificación documentada, que constituye evidencia suficiente de la calidad del conjunto de datos para el modelamiento.

3.3 Exploración adicional: relación entre Job_Title y la variable objetivo

En una primera iteración de esta fase, Job_Title se excluyó del conjunto de predictores por ser nominal de 20 categorías (ver justificación original en la sección 3.4). Sin embargo, dado que los 15 predictores numéricos/ordinales restantes mostraron una relación muy débil con Automation_Probability_2030 (Fase 1), se exploró si el propio Job_Title concentraba señal predictiva relevante, calculando el promedio de la variable objetivo por cargo.




Figura 2. Probabilidad de automatización promedio por cargo (Job_Title).

El promedio de Automation_Probability_2030 por cargo se agrupa en **tres niveles muy nítidos**: un grupo de riesgo bajo ($\approx 0,17-0,18$: AI Engineer, Research Scientist, Nurse, Teacher, Doctor), un grupo de riesgo medio ($\approx 0,48-0,53$: Financial Analyst, Mechanic, Lawyer, HR Specialist, UX Researcher, Marketing Manager, Chef, Data Scientist, Software Engineer, Graphic Designer) y un grupo de riesgo alto ($\approx 0,82-0,83$: Truck Driver, Customer Support, Construction Worker, Security Guard, Retail Worker). Calculando la proporción de varianza explicada solo por el promedio de cada Job_Title (equivalente a un R^2 de agrupación), se obtiene **$\approx 0,857$** : el cargo, por sí solo, explica cerca del 86% de la varianza de la variable objetivo, muy por encima de lo obtenido con los 15 predictores numéricos/ordinales analizados en la Fase 1 (correlación de Pearson cercana a cero). Esta evidencia cuantitativa **revierte la decisión de preprocesamiento inicial**: en la sección 3.4, Job_Title se incorpora como predictor.

3.4 Selección y codificación de variables

A la luz de la exploración anterior, se adoptan las siguientes decisiones técnicas para construir la matriz de predictores:

- Education_Level — **codificación ordinal**: se mapea High School=1, Bachelor's=2, Master's=3, PhD=4, replicando el criterio ya utilizado en la Fase 1, dado que es una variable categórica con orden natural.

- Job_Title — **incorporada mediante codificación one-hot** (`pd.get_dummies`, con `drop_first=True` para evitar la trampa de la variable dummy), generando 19 columnas binarias sobre las 20 categorías del cargo. La sección 3.3 mostró que esta variable, por sí sola, explica ~86% de la varianza de `Automation_Probability_2030`; excluirla —como se hizo en una primera iteración de esta fase, priorizando parsimonia sobre poder predictivo— descartaba la señal más relevante disponible en el dataset.
- Risk_Category — **variable excluida**: esta variable se deriva directamente de `Automation_Probability_2030` mediante un corte por umbrales (Low: 0.05–0.30, Medium: 0.31–0.70, High: 0.71–0.95). Incluirla como predictora constituiría una fuga de información (data leakage), ya que el modelo aprendería a partir de una versión discretizada de la propia variable objetivo.

El conjunto final de predictores queda compuesto por **34 variables**: las 15 numéricas/ordinales ya descritas (`Average_Salary`, `Years_Experience`, `Education_Level` codificada, `AI_Exposure_Index`, `Tech_Growth_Factor`, `Skill_1–Skill_10`) más las **19 columnas dummy de `Job\_Title`** (categoría de referencia: "AI Engineer").

3.5 Partición entrenamiento/prueba y escalamiento

El código separa las características predictoras en `X` (3.000×34) y la variable objetivo en `y` (3.000). Luego aplica una partición de 80% para entrenamiento y 20% para prueba mediante `train_test_split`, con `random_state=42` para asegurar la reproducibilidad de los tres modelos. Posteriormente, las variables predictoras se estandarizan con `StandardScaler`, ajustado únicamente sobre `X_train` para evitar filtrar información del conjunto de prueba. Este paso es especialmente relevante para la regresión lineal y, sobre todo, para la red neuronal, dado que ambos son sensibles a la escala de las variables (Ruete, 2026a; Ruete, 2026c; scikit-learn Developers, 2026b).




Figura 3. Partición de observaciones para entrenamiento y prueba.

Tabla 2. Muestra de características escaladas en `X_train` (primeras columnas).

Índice	Average_Salary	Years_Experience	Education_Level	AI_Exp.	Tech_Growth
0	0.4716	0.0422	1.3699	0.2809	0.7099
1	1.3328	1.1839	0.4794	-1.5421	0.2605
2	0.1092	0.3848	-1.3016	-1.3668	-0.7075

Justificación técnica: el escalador se ajusta con `X_train` y luego se aplica tanto a `X_train` como a `X_test`. Esta práctica evita filtrar información del conjunto de prueba durante el entrenamiento y permite evaluar los modelos bajo condiciones más cercanas a datos no vistos, garantizando comparabilidad entre los tres algoritmos implementados.

IV. Modelo de regresión lineal multivariable

La regresión lineal se utiliza como modelo base porque ofrece una primera aproximación interpretable de la relación entre los predictores y una variable continua. En términos conceptuales, busca una combinación lineal de variables que minimice la suma de errores cuadrados entre los valores reales y los predichos. El apunte de regresión lineal la presenta como punto de partida para comprender modelos de respuesta continua, coeficientes y evaluación del ajuste (Ruete, 2026a). Dado que ID2.1 admite regresión lineal simple, polinomial o multivariable, y que se dispone de 34 predictores (15 numéricos/ordinales + 19 dummies de Job_Title), se implementa una **regresión lineal multivariable**, consistente con el ejemplo de referencia entregado para esta fase.

4.1 Variables utilizadas y evidencia de ejecución

En el código, el modelo LinearRegression se entrena con X_train_scaled y y_train, usando las 34 variables predictoras descritas en la sección 3.4. Luego se generan predicciones sobre X_test_scaled y se calculan MSE, RMSE y R².

Tabla 3. Resultados obtenidos por el modelo de regresión lineal multivariable.

Resultado	Valor
Primeras 5 predicciones	[0.5035, 0.8432, 0.4790, 0.4742, 0.5027]
MSE	0.0087
RMSE	0.0933
R ²	0.8638

4.2 Interpretación inicial

A diferencia de la primera iteración de esta fase (sin Job_Title, R²≈0,01), el modelo lineal multivariable con las 34 variables alcanza un **R² ≈ 0,864** sobre el conjunto de prueba: explica cerca del 86% de la varianza de Automation_Probability_2030, con un RMSE ≈ 0,093 (error típico de ±9,3 puntos porcentuales de probabilidad, frente a ±25 puntos porcentuales del modelo sin Job_Title). Este salto de desempeño confirma, con evidencia predictiva directa sobre datos de prueba, el hallazgo exploratorio de la sección 3.3. Los coeficientes con mayor magnitud absoluta corresponden, de forma consistente, a las dummies de Job_Title del grupo de riesgo alto (Security Guard, Construction Worker, Truck Driver, Retail Worker, Customer Support; coeficientes ≈0,14-0,15) y del grupo de riesgo medio (Graphic Designer, Software Engineer, Data Scientist, UX Researcher; coeficientes ≈0,07-0,08), muy por encima de las 15 variables numéricas/ordinales originales (Anexo A, Figura A2). Esto confirma que **el cargo es, con diferencia, el predictor dominante** de la probabilidad de automatización en este dataset.

V. Modelo de árboles de decisión para regresión

El árbol de decisión para regresión es un modelo no paramétrico que divide recursivamente el espacio de características en regiones, asignando a cada una la predicción promedio de Automation_Probability_2030 observada en las muestras de entrenamiento que caen en ella. Esta lógica permite capturar relaciones no lineales e interacciones entre variables que la regresión lineal no puede representar, aunque también puede aumentar el riesgo de sobreajuste si no se controla su profundidad (Ruete, 2026b).

5.1 Configuración mínima e implementación

En el notebook se implementa DecisionTreeRegressor con max_depth=8 y min_samples_leaf=10, sobre X_train_scaled. La profundidad se incrementó respecto de la primera iteración (antes max_depth=3) porque separar 34 predictores —19 de ellos dummies binarias de Job_Title— requiere más niveles de partición.

Hiperparámetro	Valor	Justificación
max_depth	8	Limita la profundidad máxima del árbol para controlar el sobreajuste, permitiendo suficientes niveles para separar las dummies de Job_Title.
min_samples_leaf	10	Evita hojas con muy pocas observaciones (sobreajuste local).
criterion	squared_error (por defecto)	Minimiza el error cuadrático en cada partición.
random_state	42	Permite reproducir los resultados.

Tabla 4. Resultados obtenidos por el modelo de árbol de decisión.

Resultado	Valor
Primeras 5 predicciones	[0.4980, 0.8491, 0.4980, 0.4980, 0.4980]
MSE	0.0186
RMSE	0.1366
R ²	0.7079

5.2 Interpretación del comportamiento

El árbol alcanza un $R^2 \approx 0,708$ sobre el conjunto de prueba: una mejora enorme respecto de la primera iteración sin Job_Title ($R^2 \approx -0,02$), pero **inferior** a la regresión lineal ($R^2 \approx 0,864$) y a la red neuronal ($R^2 \approx 0,847$; ver sección VII). El feature_importances_ (Anexo A, Figura A3) confirma que el modelo se apoya casi exclusivamente en dummies de Job_Title —Nurse, Doctor, Teacher, Research Scientist (grupo de riesgo bajo) y Truck Driver, Retail Worker, Construction Worker, Security Guard (grupo de riesgo alto)—, mientras que las 15 variables numéricas/ordinales originales aportan una importancia prácticamente nula.

La brecha de desempeño frente a la regresión lineal se explica por una limitación estructural del árbol: al estar Job_Title codificado como 19 columnas binarias independientes, separar los tres grupos de riesgo requiere **varias particiones sucesivas** (una por cada dummy relevante), mientras que un modelo lineal asigna un coeficiente directo a cada categoría en un solo paso. Con max_depth=8 el árbol no alcanza a explotar toda la señal disponible; una profundidad mayor o un modelo de ensamble como Random Forest —con manejo más eficiente de variables categóricas— probablemente cerraría esa brecha, a costa de mayor riesgo de sobreajuste y menor interpretabilidad (ver sección VIII).

VI. Modelo de redes neuronales para regresión

La red neuronal artificial (Perceptrón Multicapa, MLP) se incorpora como modelo avanzado de regresión, capaz de aproximar relaciones no lineales mediante capas, pesos y funciones de activación. Según el apunte de redes neuronales, estos modelos aprenden representaciones intermedias y pueden capturar interacciones complejas, pero requieren atención a la escala de los datos, los hiperparámetros y el riesgo de sobreajuste (Ruede, 2026c).

6.1 Configuración mínima e implementación

El notebook utiliza MLPRegressor con una capa oculta de 16 neuronas, activación ReLU, optimizador Adam, regularización L2 ($\alpha=0.01$) para contener el sobreajuste dado el tamaño acotado del dataset, máximo de 1.000 iteraciones, random_state=42 y early_stopping=True. En la búsqueda de hiperparámetros, arquitecturas más grandes (32, 64 o dos capas ocultas) mejoraban el ajuste de entrenamiento pero no el de prueba —señal de sobreajuste—, por lo que se optó por la configuración más simple que generaliza mejor.

Hiperparámetro	Valor	Interpretación
hidden_layer_sizes	(16,)	Una capa oculta de 16 neuronas; arquitecturas mayores sobreajustaban sin mejorar el desempeño en prueba.
activation	relu	Función de activación no lineal en la capa oculta.
solver	adam	Optimizador adaptativo utilizado para entrenar la red.
alpha	0.01	Regularización L2, para reducir el riesgo de sobreajuste.
max_iter	1000	Número máximo de iteraciones de entrenamiento.
early_stopping	True	Detiene el entrenamiento si no mejora la validación.
random_state	42	Permite reproducibilidad.

Tabla 5. Resultados obtenidos por el modelo de red neuronal MLP.

Resultado	Valor
Iteraciones hasta early stopping	244
Primeras 5 predicciones	[0.4552, 0.8673, 0.4629, 0.4844, 0.5028]
MSE	0.0098
RMSE	0.0988
R ²	0.8470

6.2 Interpretación del comportamiento

La curva de pérdida de entrenamiento (Anexo A, Figura A4) muestra una disminución rápida y estable del error, hasta activarse el criterio de `early_stopping` en la iteración 244. El MLP alcanza un **R² ≈ 0,847** sobre el conjunto de prueba, muy cercano al de la regresión lineal (R²≈0,864) y muy por encima del árbol de decisión (R²≈0,708). El salto de desempeño respecto de la primera iteración de esta fase (sin `Job_Title`, R²≈-0,02) confirma nuevamente que la señal predictiva del dataset reside casi por completo en la variable `Job_Title`, y no requiere de la capacidad de la red para modelar interacciones no lineales complejas entre las 15 variables numéricas/ordinales originales. A diferencia del árbol de decisión, el MLP no ofrece una medida directa de importancia de variables, lo que limita su interpretabilidad para explicar a los clientes de NextWork Advisory por qué un cargo específico obtiene una determinada probabilidad de automatización.

VII. Evaluación de modelos de regresión

La evaluación de los modelos de regresión se realiza mediante métricas que resumen el error entre los valores reales y predichos sobre el conjunto de prueba (`x_test`, `y_test`). En esta fase se reportan MSE, RMSE y R², tal como solicita la actividad. El MSE penaliza con fuerza los errores grandes; el RMSE devuelve el error a las mismas unidades de la variable objetivo (probabilidad, 0-1); y R² mide la proporción de variabilidad explicada por el modelo (Ruete, 2026d).

Tabla 6. Reporte tabulado de métricas de regresión sobre datos de prueba, ordenado por R².

Modelo	MSE	RMSE	R ²
Regresión Lineal	0.008697	0.093258	0.863768
Red Neuronal (MLP)	0.009765	0.098819	0.847035
Árbol de Decisión	0.018647	0.136554	0.707910

Interpretación integrada: como referencia de contraste, predecir siempre el promedio de Automation_Probability_2030 observado en entrenamiento sobre el conjunto de prueba arroja un MSE $\approx$ 0,0639. Los tres modelos implementados en esta iteración —incorporando Job_Title— reducen ese error entre 6 y 7 veces, evidencia directa de que ahora sí capturan una señal predictiva sustantiva. La regresión lineal obtiene el MSE y RMSE más bajos y el R^2 más alto del grupo, seguida muy de cerca por la red neuronal MLP; el árbol de decisión, si bien mejora drásticamente respecto de la primera iteración de esta fase, queda rezagado frente a los otros dos modelos.




Figura 4. Comparación de MSE, RMSE y R^2 entre los tres modelos implementados.

Lectura técnica: en MSE y RMSE, valores más bajos son mejores; en R^2 , valores más cercanos a 1 indican mayor proporción de variabilidad explicada. Las tres métricas son consistentes entre sí: la regresión lineal y la red neuronal MLP dominan claramente al árbol de decisión, y ambas explican más del 84% de la varianza de la variable objetivo sobre datos no vistos durante el entrenamiento.

VIII. Comparación de modelos

La comparación no debe limitarse a identificar el modelo con el mayor R^2 . Una decisión analítica completa debe considerar desempeño, interpretabilidad, complejidad y pertinencia para el objetivo del proyecto. La rúbrica solicita identificar el modelo de mejor desempeño, discutir ventajas y limitaciones, y justificar la elección en función de los resultados obtenidos.

Tabla 7. Comparación de ventajas, limitaciones y lectura de resultados por modelo.

Modelo	Ventajas	Limitaciones	Lectura del resultado
Regresión Lineal	Alta interpretabilidad (un coeficiente directo por categoría de Job_Title); mejor R^2 del grupo; bajo riesgo de sobreajuste.	Asume aditividad entre predictores; con 34 variables y 2.400 observaciones de entrenamiento, conviene validar estabilidad con validación cruzada.	MSE=0.0087, R^2 =0.8638. Mejor métrica del grupo.
Árbol de Decisión	Interpretable mediante reglas e importancia de variables; identifica igualmente los tres grupos de riesgo.	Necesita varias particiones sucesivas para explotar dummies binarias de Job_Title; con profundidad acotada, queda rezagado.	MSE=0.0186, R^2 =0.7079. Peor métrica del grupo.
Red Neuronal (MLP)	R^2 muy cercano al modelo lineal; capacidad para modelar relaciones no lineales adicionales.	Menor interpretabilidad ('caja negra'); no aporta mejora sobre la regresión lineal pese a su mayor complejidad.	MSE=0.0098, R^2 =0.8470. Segundo mejor resultado.




Figura 5. Comparación conceptual entre interpretabilidad, flexibilidad y riesgo analítico.

8.1 Elección analítica fundamentada

La **regresión lineal multivariable** obtiene el menor MSE/RMSE y el mayor R^2 ($\approx 0,86$), seguida muy de cerca por la red neuronal MLP ($R^2 \approx 0,85$) y, con una brecha mayor, por el árbol de decisión ($R^2 \approx 0,71$). Este resultado contrasta radicalmente con la primera iteración de esta fase, en la que los tres modelos —sin Job_Title— obtenían R^2 cercano a 0: el cambio no proviene de un algoritmo distinto, sino de **preprocesamiento**, al incorporar la variable que concentra $\sim 86\%$ de la varianza de la variable objetivo (sección 3.3). Que el modelo más simple iguale o supere a los modelos no lineales es consistente con la naturaleza de la señal: la probabilidad de automatización es casi constante dentro de cada categoría de cargo, una relación que un coeficiente por categoría (regresión lineal) captura de forma directa, sin necesitar la flexibilidad adicional de un árbol o una red neuronal.

Por su desempeño superior e interpretabilidad directa (cada coeficiente es atribuible a una categoría de cargo), se recomienda la **regresión lineal como modelo preferente** para explicar resultados a los clientes de NextWork Advisory. La red neuronal, pese a su mayor complejidad, no logra superarla, lo que sugiere que su flexibilidad adicional no es necesaria para este problema. El árbol de decisión, con la configuración mínima utilizada, queda rezagado; una versión más profunda o un modelo de ensamble (Random Forest, línea de mejora para F3-F4) probablemente cerraría esa brecha. Esta elección se retoma y proyecta en las conclusiones.

IX. Notebook F2_Regresion.ipynb y documentación del proceso

El notebook F2_Regresion.ipynb constituye la evidencia técnica del desarrollo realizado durante esta fase. De acuerdo con las instrucciones de la actividad, el informe, el notebook y el repositorio deben formar un mismo flujo trazable. Por ello, cada sección de este informe se vincula con una etapa del código y con un resultado verificable, tal como se resume en la Tabla 8.

Tabla 8. Trazabilidad entre las etapas del notebook y las secciones del informe.

Etapas del notebook	Código o acción principal	Evidencia esperada	Relación con informe
Carga de datos	<code>pd.read_csv("AI_Impact_on_Jobs_2030.csv")</code>	Primeras filas y recuento de nulos.	Sección III.
Exploración Job_Title	<code>df.groupby("Job_Title")[...].mean()</code>	Medias por cargo y R^2 de agrupación ($\approx 0,857$).	Sección III.
Preparación X/y	Codificación ordinal + <code>pd.get_dummies(Job_Title)</code>	Dimensiones de X e y (3.000×34 y 3.000).	Sección III.

Partición	<code>train_test_split(test_size=0.20, random_state=42)</code>	Tamaños 2.400/600.	Sección III.
Escalamiento	<code>StandardScaler().fit(X_train)</code>	Primeras filas de <code>X_train_scaled</code> .	Sección III.
Modelo lineal	<code>LinearRegression().fit(...)</code>	Predicciones, MSE, RMSE y R^2 .	Sección IV.
Árbol	<code>DecisionTreeRegressor(max_depth=8, min_samples_leaf=10)</code>	Predicciones, importancias, MSE, RMSE y R^2 .	Sección V.
MLP	<code>MLPRegressor(hidden_layer_sizes=(16,), alpha=0.01, early_stopping=True)</code>	Curva de pérdida, MSE, RMSE y R^2 .	Sección VI.
Comparación	DataFrame con Modelo, MSE, RMSE y R^2	Tabla ordenada y gráficos comparativos.	Secciones VII y VIII.

9.1 Estructura del repositorio

El proyecto se encuentra versionado en el repositorio del equipo: MCDI504 (rama main, remoto origin: github.com/robertomoncada-blip/Magister_ciencia_datos). El código y los datos siguen la siguiente estructura:

Elemento	Descripción
<code>/notebooks/F1_Definicion.ipynb</code>	Notebook de la Fase 1: definición del problema y análisis exploratorio.
<code>/notebooks/F2_Regresion.ipynb</code>	Notebook de esta fase, con celdas narrativas, código ejecutable y resultados.
<code>/data/AI_Impact_on_Jobs_2030.csv</code>	Dataset original (3.000 registros), común a ambas fases.
<code>/figures/</code>	Gráficos generados por ambos notebooks (prefijo <code>f2_</code> para esta fase).
<code>/docs/</code>	Informes entregables de cada fase (Word y PDF).
<code>requirements.txt, Readme.md</code>	Dependencias y documentación general del proyecto.

La documentación señala las versiones principales de las librerías usadas: pandas, NumPy, scikit-learn (1.9.0), Matplotlib y Seaborn, declaradas en `requirements.txt`. Esto fortalece la reproducibilidad y permite que cualquier integrante del equipo ejecute el mismo flujo analítico y obtenga resultados idénticos, dado el uso consistente de `random_state=42` en las tres etapas de modelamiento.

X. Conclusiones

La Fase 2 permitió implementar un pipeline completo de regresión supervisada sobre el dataset AI Impact on Jobs 2030, retomando la línea de análisis complementaria identificada en la Fase 1. El preprocesamiento incluyó una **iteración basada en evidencia**: una primera versión con 15 predictores numéricos/ordinales (excluyendo `Job_Title` por ser nominal de 20 categorías) arrojó R^2 cercano a 0 en los tres modelos. Un análisis exploratorio adicional (sección 3.3) mostró que el promedio de `Automation_Probability_2030` por `Job_Title` explica por sí solo ~86% de la varianza de la variable objetivo, lo que motivó incorporar `Job_Title` mediante codificación one-hot (19 dummies) al conjunto final de 34 predictores, manteniendo la exclusión justificada de `Risk_Category` (fuga de información).

Con `Job_Title` incorporado, los tres modelos mejoraron drásticamente: **Regresión Lineal** (MSE=0,0087, RMSE=0,0933, R^2 =0,8638), **Red Neuronal MLP** (MSE=0,0098, RMSE=0,0988, R^2 =0,8470) y **Árbol de Decisión** (MSE=0,0186, RMSE=0,1366, R^2 =0,7079), todos muy por debajo del MSE de referencia de predecir el promedio ($\approx$ 0,0639).

Conclusión comparativa: la regresión lineal multivariable obtiene el mejor desempeño, seguida muy de cerca por la red neuronal; el árbol de decisión queda rezagado por la dificultad estructural de particionar 19 dummies binarias con una profundidad acotada. Que el modelo más simple iguale o supere a los más flexibles confirma que la relación dominante en los datos —probabilidad de automatización casi constante dentro de

cada categoría de cargo— es esencialmente **aditiva por categoría**, no una interacción no lineal compleja entre variables numéricas.

Implicancias para la continuidad del proyecto: para NextWork Advisory, Job_Title es el predictor operativamente más útil del riesgo de automatización, muy por encima de salario, experiencia, educación, índices de exposición a IA o habilidades. Como líneas de mejora para las fases siguientes (F3-F4) se identifican: (i) validar la estabilidad de los coeficientes y del desempeño mediante validación cruzada (GridSearchCV/RandomizedSearchCV), dado que el dataset tiene solo ~120-175 observaciones por categoría de cargo; (ii) explorar Random Forest para el árbol de decisión, que maneja variables categóricas de forma más eficiente que un único árbol; (iii) evaluar si las 15 variables numéricas/ordinales aportan señal incremental dentro de cada categoría de cargo (interacciones Job_Title × variable numérica), en lugar de solo a nivel agregado; y (iv) dado que Job_Title explica gran parte de la varianza tanto de Automation_Probability_2030 como de Risk_Category (Fase 1), comparar directamente el enfoque de regresión de esta fase con el de clasificación de la Fase 1 usando el mismo conjunto de predictores ampliado.

XI. Uso de fuentes, citación y referencias

El informe utiliza fuentes docentes de la asignatura, documentación técnica oficial y una fuente académica complementaria. La selección responde al criterio de la actividad, que exige fundamentar decisiones conceptuales, metodológicas y técnicas mediante referencias integradas en el texto y listadas en formato APA 7.^a edición.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An introduction to statistical learning: With applications in Python. Springer. <https://doi.org/10.1007/978-3-031-38747-0>

pandas Development Team. (2026). pandas documentation. <https://pandas.pydata.org/docs/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830. <https://jmlr.org/papers/v12/pedregosa11a.html>

Ruete, D. (2026a). Regresión lineal simple, polinomial y multivariable [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Ruete, D. (2026b). Regresión con árboles de decisión [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Ruete, D. (2026c). Regresión con redes neuronales artificiales [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Ruete, D. (2026d). Evaluación de modelos de regresión [Apunte]. Universidad Andrés Bello, Santiago, Chile.

scikit-learn Developers. (2026a). sklearn.linear_model.LinearRegression. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

scikit-learn Developers. (2026b). sklearn.model_selection.train_test_split and sklearn.preprocessing.StandardScaler. scikit-learn. <https://scikit-learn.org/stable/>

scikit-learn Developers. (2026c). sklearn.tree.DecisionTreeRegressor. scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html>

scikit-learn Developers. (2026d). sklearn.neural_network.MLPRegressor. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html

Distribución de fuentes según lo exigido por la rúbrica: 4 fuentes de material docente (Ruete, 2026a-d), 5 fuentes de documentación técnica oficial (pandas, scikit-learn) y 1 fuente académica complementaria (James et al., 2023), superando el mínimo de 5 fuentes distribuidas en las tres categorías solicitadas.

XII. Anexos

Anexo A. Figuras complementarias generadas en el notebook

Las siguientes figuras, generadas directamente en F2_Regresion.ipynb, complementan la evidencia presentada en las secciones IV a VI del informe.




Figura A1. Distribución de Automation_Probability_2030 en el dataset completo.




Figura A2. Coeficientes del modelo de regresión lineal (variables estandarizadas).




Figura A3. Importancia de variables del árbol de decisión.




Figura A4. Curva de pérdida durante el entrenamiento de la red neuronal MLP.

Anexo B. Fragmentos de código fuente

Los siguientes fragmentos sintetizan las secciones del notebook que producen las evidencias principales del informe. El equipo debe conservar el notebook completo en el repositorio y asegurar que los resultados mostrados en el informe coincidan con la última ejecución.

Exploración de Job_Title

```
medias_por_cargo = df.groupby("Job_Title")["Automation_Probability_2030"].mean()
medias_por_fila = df.groupby("Job_Title")["Automation_Probability_2030"].transform("mean")
ss_entre_grupos = ((medias_por_fila - df["Automation_Probability_2030"].mean()) ** 2).sum()
ss_total = ((df["Automation_Probability_2030"] - df["Automation_Probability_2030"].mean()) ** 2).sum()
r2_agrupacion = ss_entre_grupos / ss_total # ~0.857
```

Preparación de datos

```
orden_educacion = {"High School": 1, "Bachelor's": 2, "Master's": 3, "PhD": 4}
df["Education_Level_Num"] = df["Education_Level"].map(orden_educacion)
job_title_dummies = pd.get_dummies(df["Job_Title"], prefix="Job_Title", drop_first=True).astype(int)
X = pd.concat([df[variables_numericas], job_title_dummies], axis=1)
y = df["Automation_Probability_2030"]
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42)
scaler = StandardScaler().fit(X_train)
X_train_scaled = scaler.transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Regresión lineal

```
linear_model = LinearRegression()
linear_model.fit(X_train_scaled, y_train)
y_pred_linear = linear_model.predict(X_test_scaled)
mse_linear = mean_squared_error(y_test, y_pred_linear)
rmse_linear = np.sqrt(mse_linear)
r2_linear = r2_score(y_test, y_pred_linear)
```

Árbol de decisión

```
decision_tree_model = DecisionTreeRegressor(max_depth=8, min_samples_leaf=10, random_state=42)
decision_tree_model.fit(X_train_scaled, y_train)
y_pred_tree = decision_tree_model.predict(X_test_scaled)
```

Red neuronal MLP

```
mlp_model = MLPRegressor(hidden_layer_sizes=(16,), activation="relu", solver="adam",
                          alpha=0.01, max_iter=1000, random_state=42, early_stopping=True)
mlp_model.fit(X_train_scaled, y_train)
y_pred_mlp = mlp_model.predict(X_test_scaled)
```

Anexo C. Checklist de alineación con la rúbrica

Criterio de rúbrica	Evidencia incluida en el informe	Estado
C1. Introducción y contextualización	Contexto, situación, objetivo analítico y relación con variable continua.	Incluido
C2. Datos y preprocesamiento	Variables, nulos, X/y, train/test, StandardScaler y justificación de exclusiones.	Incluido
C3. Regresión lineal	Modelo, variables, evidencia de ejecución, resultados e interpretación.	Incluido
C4. Árbol de decisión	Hiperparámetros, evidencia de ejecución, resultados e interpretación.	Incluido
C5. Red neuronal	Hiperparámetros, evidencia de ejecución, resultados e interpretación.	Incluido
C6. Evaluación de modelos	MSE, RMSE y R ² tabulados por modelo, con interpretación.	Incluido
C7. Comparación de modelos	Ventajas, limitaciones, mejor modelo y justificación de la elección.	Incluido
C8. Notebook y documentación	Trazabilidad entre notebook, informe y repositorio (Tabla 8).	Incluido
C9. Conclusiones	Síntesis comparativa y proyección para la continuidad del proyecto.	Incluido
C10. Formato institucional	Plantilla institucional, tamaño carta, tipografía Arial 10,5-11.	Incluido
C12. Fuentes APA	11 fuentes distribuidas en docente, técnica oficial y académica.	Incluido
C13. Anexos	Figuras complementarias, fragmentos de código y checklist.	Incluido

Nota final: antes de entregar, el equipo debe revisar la ortografía y numeración del documento, confirmar que el notebook `F2_Regresion.ipynb` ejecuta sin errores con la última versión del dataset, y exportar el documento final a PDF en tamaño carta con el nombre `MCDI504_S2_1_GRUPO5.docx / .pdf`.