

MCDI504

MACHINE LEARNING I

INFORME FINAL DE PROYECTO — FASE 3:

CLASIFICACIÓN SUPERVISADA MEDIANTE REDES

NEURONALES

Estimación del riesgo de automatización de cargos hacia 2030 — Caso NextWork Advisory

Curso: MCDI504 - Machine Learning I

Docente: David Ruete

Grupo: 5

Integrantes:

- Arturo Knopke Vera
- Nicolás Soletic Cobos
- Sebastián Navarrete Soto
- Roberto Moncada González

Repositorio Github: https://github.com/robertomoncada-blip/Magister_ciencia_datos.git

Fecha de entrega: 23 de agosto de 2026

Índice

I. Introducción y contextualización.....	3
II. Descripción del conjunto de datos y preparación para redes neuronales	4
2.1 Descripción general del dataset.....	4
2.2 Selección y codificación de variables.....	4
2.3 Partición entrenamiento/prueba	5
2.4 Escalado de variables: justificación para redes neuronales	5
III. Análisis exploratorio inicial y preparación de datos	6
3.1 Distribución de clases de Risk_Category	6
3.2 Relación entre Job_Title y Risk_Category	6
3.3 Relación entre la exploración, la preparación de datos y el problema de clasificación.....	7
IV. Notebook F3_RedesNeuronales.ipynb y documentación del proceso.....	8
4.1 Estructura del repositorio	8
V. Red neuronal con una capa oculta.....	9
VI. Red neuronal con dos capas ocultas	10
VII. Red neuronal con tres capas ocultas	11
VIII. Evaluación de desempeño de redes neuronales.....	12
IX. Comparación de arquitecturas de redes neuronales	13
X. Conclusiones	15
XI. Uso de fuentes, citación y referencias	16
XII. Anexos	17
Anexo A. Fragmentos de código fuente.....	17
Anexo B. Distribución de Risk_Category por Job_Title	17
Anexo C. Reporte de clasificación por clase de las tres arquitecturas	18
Anexo D. Curvas de pérdida comparadas de las tres arquitecturas.....	18
Anexo E. Checklist de alineación con la rúbrica	19

I. Introducción y contextualización

El presente informe corresponde a la Fase 3 del Proyecto del curso MCDI504 - Machine Learning I. En la Fase 1, el equipo definió el problema de negocio de NextWork Advisory, una consultora ficticia de estrategia de talento que utiliza el dataset AI Impact on Jobs 2030 para evaluar el riesgo de automatización de distintos cargos hacia el año 2030 y justificó un enfoque de aprendizaje supervisado de clasificación multiclase sobre la variable ordinal Risk_Category (Low/Medium/High). En la Fase 2, el equipo exploró la alternativa de regresión sobre la variable continua Automation_Probability_2030 y encontró evidencia clave para el preprocesamiento: el cargo (Job_Title) explica por sí solo cerca del 86% de la varianza de la variable objetivo continua, muy por encima del resto de las variables numéricas/ordinales del dataset.

La Fase 3 retoma el problema de clasificación original planteado en la Fase 1 —predecir Risk_Category— y exige implementar y comparar redes neuronales superficiales (Perceptrón Multicapa, MLPClassifier) con una, dos y tres capas ocultas, evaluando su desempeño mediante matrices de confusión y métricas de clasificación. El problema analítico consiste en estimar Risk_Category a partir de los mismos predictores derivados del perfil laboral validados en la Fase 2: Average_Salary, Years_Experience, Education_Level (codificada ordinalmente), AI_Exposure_Index, Tech_Growth_Factor, los diez puntajes de habilidades Skill_1 a Skill_10, y el cargo (Job_Title, codificado mediante variables dummy). Se excluye Automation_Probability_2030 del conjunto de predictores, porque esta variable da origen a Risk_Category mediante un corte directo por umbrales y su inclusión constituiría una fuga de información (data leakage).

Desde la perspectiva metodológica, esta fase busca generar evidencia técnica para la toma de decisiones de NextWork Advisory: no basta con entrenar los tres modelos, sino que se deben interpretar sus resultados, contrastar sus métricas y justificar qué arquitectura resulta más pertinente para continuar el proyecto. Esta lógica se sostiene en la evaluación integrada de accuracy, precision, recall y F1-score (promediados de forma macro para no sobrestimar el desempeño por la clase mayoritaria), que en conjunto permiten leer la capacidad de las redes neuronales para distinguir las tres categorías de riesgo de automatización (scikit-learn Developers, 2026a).

Elemento	Descripción aplicada al caso
Contexto del caso	Estimación del riesgo de automatización de cargos hacia 2030 (NextWork Advisory).
Dataset	AI Impact on Jobs 2030 (3.000 perfiles laborales, 18 columnas), común a las Fases 1, 2 y 3.
Tipo de problema	Clasificación supervisada multiclase (3 clases).
Variable objetivo	Risk_Category: Low / Medium / High.
Variables predictoras	34: 15 numéricas/ordinales + 19 dummies de Job_Title (criterio validado en la Fase 2).
Modelos implementados	MLPClassifier con una, dos y tres capas ocultas.

Tabla 1. Síntesis contextual de la Fase 3.

II. Descripción del conjunto de datos y preparación para redes neuronales

2.1 Descripción general del dataset

El conjunto de datos AI Impact on Jobs 2030 contiene 3.000 observaciones (perfiles laborales simulados) y 18 columnas: el cargo (Job_Title, 20 categorías), variables numéricas de perfil (Average_Salary, Years_Experience), el nivel educativo (Education_Level, ordinal), dos índices de contexto (AI_Exposure_Index, Tech_Growth_Factor), diez puntajes de habilidades (Skill_1–Skill_10, escala 0-1) y dos variables de resultado relacionadas: Automation_Probability_2030 (continua, 0-1) y Risk_Category (categórica ordinal, derivada de la anterior por corte de umbrales: Low 0.05–0.30, Medium 0.31–0.70, High 0.71–0.95). El dataset es el mismo utilizado en las Fases 1 y 2, lo que asegura coherencia entre las tres etapas del proyecto. La carga del dataset (`df.isnull().sum()`) confirma nuevamente 0 valores faltantes en las 18 columnas, por lo que no se requiere imputación ni eliminación de registros.

Variable	Rol	Descripción
Risk_Category	Objetivo (target)	Categoría ordinal de riesgo de automatización: Low, Medium o High.
Automation_Probability_2030	Excluida (fuga de información)	Da origen a Risk_Category por corte de umbrales; incluirla filtraría la propia etiqueta objetivo.
Average_Salary	Predictora	Salario promedio anual del cargo (USD).
Years_Experience	Predictora	Años de experiencia asociados al cargo.
Education_Level	Predictora (codificada ordinal)	Nivel educativo: High School < Bachelor's < Master's < PhD.
AI_Exposure_Index	Predictora	Índice de exposición del cargo a la inteligencia artificial (0-1).
Tech_Growth_Factor	Predictora	Factor de crecimiento tecnológico del sector (0.5-1.5).
Skill_1 – Skill_10	Predictoras	Diez puntajes de dominio de habilidades del perfil (0-1).
Job_Title	Predictora (codificada dummy)	Cargo del perfil laboral (20 categorías); predictor dominante identificado en la Fase 2.

Tabla 2. Variables relevantes del dataset AI Impact on Jobs 2030 para el problema de clasificación.

2.2 Selección y codificación de variables

Se replica el criterio de selección de variables validado en la Fase 2, que mostró evidencia cuantitativa de que Job_Title concentra la mayor parte de la señal predictiva del dataset (~86% de la varianza de Automation_Probability_2030 explicada solo por el promedio de cada cargo). Las decisiones técnicas adoptadas son:

- Education_Level — codificación ordinal: se mapea High School=1, Bachelor's=2, Master's=3, PhD=4, replicando el criterio ya utilizado en las Fases 1 y 2, dado que es una variable categórica con orden natural.
- Job_Title — incorporada mediante codificación dummy (`pd.get_dummies`, con `drop_first=True`), generando 19 columnas binarias sobre las 20 categorías del cargo (categoría de referencia: 'AI

Engineer'). A diferencia de un one-hot puro, que generaría una columna por cada una de las 20 categorías, la codificación dummy omite la categoría de referencia para evitar una columna redundante. Excluir Job_Title, como en la primera iteración de la Fase 2, descartaría la señal más relevante disponible en el dataset.

- Automation_Probability_2030 — variable excluida del conjunto de predictores: Risk_Category se deriva directamente de esta variable mediante un corte por umbrales; incluirla constituiría una fuga de información (data leakage), de forma análoga a como en la Fase 2 se excluyó Risk_Category del conjunto de predictores para el problema de regresión.

El conjunto final de predictores queda compuesto por 34 variables: las 15 numéricas/ordinales ya descritas (Average_Salary, Years_Experience, Education_Level codificada, AI_Exposure_Index, Tech_Growth_Factor, Skill_1–Skill_10) más las 19 columnas dummy de Job_Title. Las dimensiones resultantes son X (3.000 × 34) e y (3.000).

Índice	Job_Title	Average_Salary	Education_Level	Risk_Category
0	Security Guard	45.795	Master's	High
1	Research Scientist	133.355	PhD	Low
2	Construction Worker	146.216	High School	High
3	Software Engineer	136.530	PhD	Medium
4	Financial Analyst	70.397	High School	Medium

Tabla 3. Primeras cinco filas observadas en la carga del dataset AI Impact on Jobs 2030 (columnas seleccionadas).

2.3 Partición entrenamiento/prueba

El código separa las características predictoras en X (3.000 × 34) y la variable objetivo en y (3.000). Dado que Risk_Category no está perfectamente balanceada (Medium concentra ~50,7% de los casos, mientras que Low y High se reparten el resto en proporciones casi idénticas entre sí), se aplica una partición de 80% para entrenamiento y 20% para prueba mediante train_test_split, con random_state=42 y stratify=y, para asegurar reproducibilidad y conservar la proporción de clases en ambos conjuntos.

Objeto	Dimensión	Proporción Low / Medium / High
X_train / y_train	(2400, 34) / (2400,)	24,62% / 50,71% / 24,67%
X_test / y_test	(600, 34) / (600,)	24,67% / 50,67% / 24,67%

Tabla 4. Dimensiones de los conjuntos de entrenamiento y prueba, y distribución de clases (partición estratificada).

2.4 Escalado de variables: justificación para redes neuronales

Las variables predictoras presentan escalas muy distintas (Average_Salary en decenas de miles de dólares versus índices, habilidades y dummies de Job_Title entre 0 y 1). Las redes neuronales entrenadas mediante descenso de gradiente (optimizador adam, usado por MLPClassifier) son particularmente sensibles a la escala de los datos de entrada: variables con rangos mucho mayores dominan el cálculo del gradiente y ralentizan o distorsionan la convergencia. Por ello se estandarizan los predictores con StandardScaler (media 0, desviación estándar 1), ajustado únicamente con los datos de entrenamiento para evitar fuga de información desde el conjunto de prueba, replicando el criterio ya utilizado para el MLP de regresión en la Fase 2 (Ruete, 2026b; scikit-learn Developers, 2026b).

Average_Salary	Years_Experience	AI_Exposure_Index	Skill_1
-0.5477	0.8371	-1.3778	-1.0909
-0.2152	-0.7754	0.0287	-1.6774
-1.4053	1.2978	1.6814	-0.6424

Tabla 5. Muestra de características escaladas en X_{train} (primeras columnas, StandardScaler).

III. Análisis exploratorio inicial y preparación de datos

3.1 Distribución de clases de Risk_Category

Se revisa la distribución de la variable objetivo en el dataset completo. Risk_Category presenta un desequilibrio moderado: Medium concentra 1.521 observaciones (50,7%), mientras que Low (739, 24,6%) y High (740, 24,7%) se reparten el resto en proporciones casi idénticas entre sí. Este desequilibrio no es severo, pero justifica dos decisiones ya adoptadas: usar stratify=y en la partición entrenamiento/prueba (sección 2.3) y reportar métricas macro-promediadas, además del accuracy, para no sobrestimar el desempeño únicamente por acertar bien en la clase mayoritaria.

Clase	Frecuencia	Proporción
Low	739	24,63%
Medium	1.521	50,70%
High	740	24,67%

Tabla 6. Distribución de la variable objetivo Risk_Category en el dataset completo.




Figura 1. Distribución de la variable objetivo Risk_Category.

3.2 Relación entre Job_Title y Risk_Category

La Fase 2 mostró que el promedio de Automation_Probability_2030 por cargo explica ~86% de la varianza de dicha variable continua, agrupándose en tres niveles muy nítidos. Dado que Risk_Category se deriva de esa misma variable por corte de umbrales, se espera un patrón equivalente al analizar la proporción de cada clase de riesgo dentro de cada Job_Title.




Figura 2. Proporción de Risk_Category por Job_Title.

El gráfico confirma el patrón anticipado: cargos como AI Engineer, Research Scientist, Nurse, Teacher y Doctor concentran casi exclusivamente observaciones de riesgo Low; cargos como Truck Driver, Retail Worker, Construction Worker, Security Guard y Customer Support concentran casi exclusivamente riesgo High; el resto de los cargos se ubica mayoritariamente en riesgo Medium. En la práctica, Job_Title funciona como un identificador casi determinístico de Risk_Category en este dataset simulado.

3.3 Relación entre la exploración, la preparación de datos y el problema de clasificación

Esta evidencia tiene tres implicancias directas para el modelamiento mediante redes neuronales:

- Justifica la inclusión de Job_Title (codificado mediante variables dummy) como predictor, decisión ya adoptada en la sección 2.2: excluirlo privaría a los modelos de la señal predictiva dominante del dataset.
- Anticipa un desempeño de clasificación muy alto en las tres arquitecturas de red neuronal implementadas (secciones V a VII), ya que el problema es, en la práctica, casi linealmente separable una vez incorporado Job_Title: no se requiere necesariamente una arquitectura profunda para capturar la relación entre predictores y Risk_Category. Esta hipótesis se contrasta empíricamente en la comparación de arquitecturas (sección IX).
- No se identifican valores faltantes ni necesidad adicional de transformación de variables más allá de la codificación (sección 2.2) y el escalado (sección 2.4) ya realizados, consistente con lo documentado en las Fases 1 y 2 para el mismo dataset.

IV. Notebook F3_RedesNeuronales.ipynb y documentación del proceso

El notebook F3_RedesNeuronales.ipynb constituye la evidencia técnica del desarrollo realizado durante esta fase. De acuerdo con las instrucciones de la actividad, el informe, el notebook y el repositorio deben formar un mismo flujo trazable. Por ello, cada sección de este informe se vincula con una etapa del código y con un resultado verificable, tal como se resume en la Tabla 7.

Etapa del notebook	Código o acción principal	Relación con el informe
Carga de datos	<code>pd.read_csv("AI_Impact_on_Jobs_2030.csv")</code>	Sección II.
Selección y codificación	<code>Education_Level_Num + pd.get_dummies(Job_Title)</code>	Sección II.
Partición y escalado	<code>train_test_split(stratify=y) + StandardScaler</code>	Sección II.
Análisis exploratorio	<code>value_counts(), crosstab(Job_Title, Risk_Category)</code>	Sección III.
MLP 1 capa oculta	<code>MLPClassifier(hidden_layer_sizes=(32,))</code>	Sección V.
MLP 2 capas ocultas	<code>MLPClassifier(hidden_layer_sizes=(32, 16))</code>	Sección VI.
MLP 3 capas ocultas	<code>MLPClassifier(hidden_layer_sizes=(32, 16, 8))</code>	Sección VII.
Evaluación	<code>confusion_matrix, accuracy/precision/recall/F1 macro</code>	Sección VIII.
Comparación	Reporte tabulado y gráfico comparativo por arquitectura	Sección IX.

Tabla 7. Trazabilidad entre las etapas del notebook y las secciones del informe.

4.1 Estructura del repositorio

El proyecto se encuentra versionado en el repositorio del equipo Magister_ciencia_datos (rama main, remoto origin: github.com/robertomoncada-blip/Magister_ciencia_datos), dentro de la carpeta MCDI504 correspondiente a la asignatura. El código y los datos siguen la siguiente estructura:

Elemento	Descripción
MCDI504/notebooks/F1_Definicion.ipynb	Notebook de la Fase 1: definición del problema y análisis exploratorio inicial.
MCDI504/notebooks/F2_Regresion.ipynb	Notebook de la Fase 2: modelos de regresión sobre <code>Automation_Probability_2030</code> .
MCDI504/notebooks/F3_RedesNeuronales.ipynb	Notebook de esta fase: modelos de clasificación mediante redes neuronales.
MCDI504/data/AI_Impact_on_Jobs_2030.csv	Dataset original (3.000 registros), común a las tres fases.
MCDI504/figures/	Gráficos y matrices de confusión generados por los tres notebooks.
MCDI504/docs/MCDI504_S3_2_GRUPO5.pdf	Informe final exportado desde Word a PDF.

Tabla 8. Estructura de repositorio utilizada para asegurar trazabilidad.

La totalidad del modelamiento se implementa sobre scikit-learn (Pedregosa et al., 2011), cuya interfaz común de estimadores permite entrenar y evaluar las tres arquitecturas con el mismo flujo de código, variando únicamente el parámetro de profundidad. El proyecto declara sus dependencias principales (pandas, NumPy, scikit-learn, Matplotlib, Seaborn) en `requirements.txt`, lo que fortalece la reproducibilidad y permite que cualquier integrante del equipo ejecute el mismo flujo analítico y obtenga resultados idénticos, dado el uso consistente de `random_state=42` en las tres arquitecturas de red neuronal.

V. Red neuronal con una capa oculta

Se implementa un Perceptrón Multicapa (MLPClassifier) con una única capa oculta: una capa de entrada de 34 neuronas (una por variable predictora), una capa oculta de 32 neuronas con activación ReLU, y una capa de salida de 3 neuronas con activación softmax (gestionada internamente por MLPClassifier para clasificación multiclase), que entrega la probabilidad de cada clase de Risk_Category (Ruede, 2026a; scikit-learn Developers, 2026b).

Hiperparámetro	Valor	Propósito
hidden_layer_sizes	(32,)	Una capa oculta de 32 neuronas.
activation	relu	Función de activación no lineal en la capa oculta.
solver	adam	Algoritmo de optimización basado en descenso de gradiente estocástico.
alpha	0.001	Regularización L2, para reducir el sobreajuste.
max_iter	1000	Máximo de épocas de entrenamiento.
early_stopping	True	Detiene el entrenamiento si no mejora en un conjunto de validación interno.
random_state	42	Reproducibilidad.

Tabla 9. Ficha técnica del MLP con una capa oculta.

Resultado	Valor
Iteraciones hasta convergencia/early stopping	40
Accuracy	0,9933
Precision (macro)	0,9912
Recall (macro)	0,9956
F1-score (macro)	0,9933

Tabla 10. Resultados del MLP con una capa oculta, calculados sobre el conjunto de prueba (600 observaciones).




Figura 3. Matriz de confusión y curva de pérdida del MLP con una capa oculta.

El modelo con una capa oculta alcanza un desempeño muy alto sobre el conjunto de prueba (accuracy y F1-score macro por sobre 0,99). La matriz de confusión muestra que las clases Low y High se predicen sin errores; la única confusión (4 casos) se concentra en la frontera entre Medium y High. La curva de pérdida decrece de forma rápida y estable, sin señales de inestabilidad en el

entrenamiento, y el criterio `early_stopping`, que detiene el ajuste cuando la pérdida de validación deja de mejorar y reserva internamente una fracción del conjunto de entrenamiento con ese fin (Ruede, 2026a; scikit-learn Developers, 2026b), detiene el ajuste en la iteración 40, muy por debajo de las 1000 épocas máximas. Este resultado es consistente con el hallazgo de la sección III: al incorporar `Job_Title`, el problema de clasificación se vuelve casi linealmente separable, por lo que una arquitectura simple —una sola capa oculta— ya es suficiente para capturar la relación entre los predictores y `Risk_Category`.

VI. Red neuronal con dos capas ocultas

Se añade una segunda capa oculta a la arquitectura anterior, buscando evaluar si una representación más profunda mejora el desempeño de clasificación. La red pasa a tener: capa de entrada (34 neuronas) → primera capa oculta (32 neuronas, ReLU) → segunda capa oculta (16 neuronas, ReLU) → capa de salida (3 neuronas, softmax).

Hiperparámetro	Valor	Propósito
<code>hidden_layer_sizes</code>	(32, 16)	Dos capas ocultas: 32 y 16 neuronas respectivamente.
<code>activation</code>	<code>relu</code>	Igual que el modelo anterior.
<code>solver</code>	<code>adam</code>	Igual que el modelo anterior.
<code>alpha</code>	0.001	Igual que el modelo anterior.
<code>max_iter</code>	1000	Igual que el modelo anterior.
<code>early_stopping</code>	<code>True</code>	Igual que el modelo anterior.
<code>random_state</code>	42	Reproducibilidad.

Tabla 11. Ficha técnica del MLP con dos capas ocultas.

Resultado	Valor
Iteraciones hasta convergencia/early stopping	27
Accuracy	0,9867
Precision (macro)	0,9848
Recall (macro)	0,9866
F1-score (macro)	0,9855

Tabla 12. Resultados del MLP con dos capas ocultas, calculados sobre el conjunto de prueba (600 observaciones).




Figura 4. Matriz de confusión y curva de pérdida del MLP con dos capas ocultas.

El modelo con dos capas ocultas también alcanza un desempeño muy alto, aunque levemente inferior al de una sola capa oculta (accuracy 0,9867 y F1-score macro 0,9855, con 8 errores frente a los 4 del modelo anterior: cuatro observaciones reales de clase Medium clasificadas como High, dos observaciones Low clasificadas como Medium y dos observaciones Low clasificadas como High). El entrenamiento converge en menos iteraciones (27) que el modelo anterior (40), lo que sugiere que la red encuentra más rápido un óptimo local, pero no necesariamente uno mejor. Este comportamiento es consistente con la hipótesis planteada en la sección III: dado que la relación entre los predictores (especialmente Job_Title) y Risk_Category es casi linealmente separable, añadir una segunda capa oculta introduce capacidad adicional que el problema no requiere, sin traducirse en una mejora de desempeño sobre el conjunto de prueba.

VII. Red neuronal con tres capas ocultas

Se profundiza aún más la arquitectura, agregando una tercera capa oculta: capa de entrada (34 neuronas) → primera capa oculta (32 neuronas) → segunda capa oculta (16 neuronas) → tercera capa oculta (8 neuronas) → capa de salida (3 neuronas, softmax).

Hiperparámetro	Valor	Propósito
hidden_layer_sizes	(32, 16, 8)	Tres capas ocultas: 32, 16 y 8 neuronas respectivamente.
activation	relu	Igual que los modelos anteriores.
solver	adam	Igual que los modelos anteriores.
alpha	0.001	Igual que los modelos anteriores.
max_iter	1000	Igual que los modelos anteriores.
early_stopping	True	Igual que los modelos anteriores.
random_state	42	Reproducibilidad.

Tabla 13. Ficha técnica del MLP con tres capas ocultas.

Resultado	Valor
Iteraciones hasta convergencia/early stopping	23
Accuracy	0,9917
Precision (macro)	0,9890
Recall (macro)	0,9945
F1-score (macro)	0,9917

Tabla 14. Resultados del MLP con tres capas ocultas, calculados sobre el conjunto de prueba (600 observaciones).




Figura 5. Matriz de confusión y curva de pérdida del MLP con tres capas ocultas.

El modelo con tres capas ocultas recupera parte del desempeño perdido por el modelo de dos capas, ubicándose entre ambos (accuracy 0,9917 y F1-score macro 0,9917, con 5 errores). Sus cinco errores corresponden en su totalidad a observaciones reales de clase Medium: cuatro clasificadas como High y una como Low. En conjunto, los tres modelos evidencian que, más allá de pequeñas variaciones asociadas a la inicialización y la optimización estocástica, la profundidad adicional no aporta una mejora sistemática sobre el modelo más simple, un patrón que se cuantifica y discute en la comparación de arquitecturas (sección IX).

VIII. Evaluación de desempeño de redes neuronales

Se consolidan las métricas accuracy, precision (macro), recall (macro) y F1-score (macro), calculadas sobre el conjunto de prueba (X_{test} , y_{test} , 600 observaciones), en un único reporte tabulado que identifica cada modelo.

Modelo	Arquitectura	Accuracy	Precision (macro)	Recall (macro)	F1-score (macro)
MLP 1 capa oculta	(32,)	0,9933	0,9912	0,9956	0,9933
MLP 3 capas ocultas	(32, 16, 8)	0,9917	0,9890	0,9945	0,9917
MLP 2 capas ocultas	(32, 16)	0,9867	0,9848	0,9866	0,9855

Tabla 15. Reporte tabulado de métricas de las tres arquitecturas de red neuronal, ordenado por F1-score (macro).

Modelo	Aciertos Low	Aciertos Medium	Aciertos High	Total errores
MLP 1 capa oculta	148 / 148	300 / 304	148 / 148	4
MLP 2 capas ocultas	144 / 148	300 / 304	148 / 148	8
MLP 3 capas ocultas	148 / 148	299 / 304	148 / 148	5

Tabla 16. Aciertos y errores por clase y arquitectura (aciertos sobre el total real de cada clase).

Las tres arquitecturas alcanzan un desempeño muy alto y muy similar entre sí (accuracy y F1-score macro por sobre 0,98 en los tres casos), muy por encima de un clasificador trivial que siempre prediga la clase mayoritaria Medium (que obtendría un accuracy $\approx 0,507$, equivalente a su proporción en el dataset, sección 3.1). Esto confirma, con evidencia directa sobre el conjunto de prueba, que la inclusión de Job_Title (sección 2.2) provee una señal casi determinística para separar las tres clases de Risk_Category, tal como se anticipó en el análisis exploratorio (sección III). Las matrices de confusión de las secciones V a VII muestran además que la confusión residual se concentra en las fronteras entre categorías contiguas, principalmente Medium/High. Los errores entre Low y High —las dos categorías más alejadas del espectro de riesgo— son prácticamente inexistentes: las arquitecturas de una y tres capas ocultas no registran ninguno, y la de dos capas ocultas presenta solo dos casos sobre 600 observaciones. Este comportamiento es coherente con el problema de clasificación planteado en la Fase 1: el modelo distingue con solidez los extremos del riesgo de automatización y concentra su margen de error en la frontera entre niveles adyacentes.

IX. Comparación de arquitecturas de redes neuronales




Figura 6. Comparación de accuracy y F1-score (macro) entre las tres arquitecturas evaluadas.

De acuerdo con el reporte tabulado de la sección VIII, la red neuronal con una capa oculta exhibe el mejor desempeño en las cuatro métricas evaluadas (accuracy, precision, recall y F1-score macro), seguida por el modelo de tres capas ocultas y, en último lugar, el modelo de dos capas ocultas. Las diferencias entre los tres modelos son, en todo caso, marginales (menos de 1 punto porcentual en F1-score macro entre el mejor y el peor).

La diferencia de desempeño entre arquitecturas no sigue un patrón de 'a mayor profundidad, mejor desempeño': el modelo de una capa oculta supera tanto al de dos como al de tres capas. Esto es coherente con la naturaleza del problema identificada en el análisis exploratorio (sección III): al incorporar Job_Title como predictor dummy, la relación entre las variables de entrada y Risk_Category se vuelve casi linealmente separable (cada categoría de cargo se asocia de forma casi exclusiva a una única clase de riesgo). En un escenario así, una red con una sola capa oculta ya cuenta con suficiente capacidad de representación; agregar capas adicionales introduce más parámetros a optimizar sin que exista una relación no lineal adicional relevante que estas puedan capturar.

Este comportamiento es consistente con el principio de que la profundidad aporta capacidad de representación jerárquica solo cuando la estructura del problema la requiere: en ausencia de esa estructura, el aumento del número de parámetros incrementa la dificultad de optimización sin traducirse en una mejor generalización (Goodfellow et al., 2016).

Arquitectura	Fortalezas	Limitaciones	Conclusión analítica
MLP 1 capa oculta	Mejor desempeño observado (accuracy 0,9933); es la arquitectura más simple y con menor número de parámetros entre las tres evaluadas.	Podría resultar insuficiente ante relaciones no lineales más complejas entre variables en fases futuras.	Arquitectura recomendada según la evidencia de esta fase.
MLP 2 capas ocultas	Mayor capacidad teórica para representar relaciones jerárquicas.	Desempeño levemente inferior (accuracy 0,9867); mayor cantidad de parámetros sin beneficio observado.	No se recomienda como mejor arquitectura preliminar.
MLP 3 capas ocultas	Recupera parte del desempeño perdido por el	Es la arquitectura con mayor número de	Alternativa razonable si se requiere mayor capacidad

	modelo de dos capas (accuracy 0,9917); mayor flexibilidad estructural.	parámetros, sin superar al modelo más simple.	representacional a futuro.
--	--	---	----------------------------

Tabla 17. Comparación cualitativa entre arquitecturas de redes neuronales.

Para el problema de clasificación de Risk_Category sobre el dataset AI Impact on Jobs 2030, la evidencia recogida en esta fase sugiere que no es necesario recurrir a arquitecturas profundas: la red neuronal con una sola capa oculta iguala o supera a las arquitecturas más profundas con una estructura de menor complejidad. Esta conclusión preliminar es coherente con el hallazgo de la Fase 2, donde el modelo más simple (regresión lineal) también igualó o superó a modelos más complejos (árbol de decisión, MLP de regresión) para el mismo dataset: en ambos casos, la señal dominante que aporta Job_Title explica por qué modelos simples resultan suficientes.

X. Conclusiones

La Fase 3 permitió implementar y comparar tres arquitecturas de red neuronal (MLPClassifier) —una, dos y tres capas ocultas— para clasificar Risk_Category (Low/Medium/High), retomando el problema de clasificación supervisada multiclase definido en la Fase 1 y el criterio de selección de variables (incluyendo Job_Title codificado mediante variables dummy) validado en la Fase 2.

Las tres arquitecturas alcanzaron un desempeño muy alto sobre el conjunto de prueba: MLP 1 capa oculta (accuracy=0,9933, F1-score macro=0,9933), MLP 2 capas ocultas (accuracy=0,9867, F1-score macro=0,9855) y MLP 3 capas ocultas (accuracy=0,9917, F1-score macro=0,9917), todos muy por encima de un clasificador trivial basado en la clase mayoritaria (accuracy $\approx$ 0,507). El modelo con una capa oculta obtuvo el mejor desempeño, seguido por el de tres capas y, en último lugar, el de dos capas ocultas; las diferencias entre las tres arquitecturas fueron marginales (menos de 1 punto porcentual).

Conclusión comparativa entre arquitecturas: el patrón observado —que la arquitectura más simple iguale o supere a las más profundas— es consistente con la evidencia exploratoria de la sección III: Job_Title provee una señal casi determinística para separar las clases de riesgo, por lo que el problema es casi linealmente separable y no requiere de la capacidad adicional de redes más profundas. Este hallazgo replica, en el contexto de clasificación, la misma conclusión obtenida en la Fase 2 para el problema de regresión (donde la regresión lineal, el modelo más simple, igualó o superó a modelos no lineales más complejos).

Implicancias para la selección del modelo final: para NextWork Advisory, se recomienda la red neuronal con una capa oculta como modelo preferente para estimar Risk_Category, dado que ofrece el mejor desempeño observado sobre el conjunto de prueba con la arquitectura de menos parámetros entre las tres evaluadas. Las matrices de confusión muestran además que los errores residuales se concentran en las fronteras entre categorías contiguas, principalmente Medium/High, y que la confusión entre Low y High es prácticamente nula (ningún caso en las arquitecturas de una y tres capas ocultas, dos casos en la de dos capas). Esto resulta relevante para priorizar la revisión manual de los casos límite en una eventual implementación operativa.

Como líneas de mejora para fases posteriores del proyecto, se identifica la conveniencia de: (i) validar la estabilidad de estos resultados mediante validación cruzada, dado que el desempeño observado es extremadamente alto y podría ser sensible a la partición particular de los datos; (ii) comparar formalmente estas redes neuronales con los modelos de clasificación tradicionales (KNN, árboles de decisión, SVM, Naïve Bayes) sobre el mismo conjunto de 34 predictores, en línea con el RA3 completo del curso; y (iii) evaluar el desempeño de los modelos si se excluyera Job_Title, para dimensionar cuánta capacidad predictiva adicional aportan efectivamente las variables numéricas/ordinales del perfil laboral una vez controlado por el cargo.

XI. Uso de fuentes, citación y referencias

El informe utiliza fuentes docentes de la asignatura, documentación técnica oficial y fuentes académicas complementarias. La selección responde al criterio de la actividad, que exige fundamentar decisiones conceptuales, metodológicas y técnicas mediante referencias integradas en el texto y listadas en formato APA 7.^a edición.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. <https://www.deeplearningbook.org/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. <https://jmlr.org/papers/v12/pedregosa11a.html>

Ruete, D. (2026a). *Redes Neuronales* [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Ruete, D. (2026b). *Regresión con redes neuronales artificiales* [Apunte]. Universidad Andrés Bello, Santiago, Chile.

scikit-learn Developers. (2026a). *Metrics and scoring: quantifying the quality of predictions*. scikit-learn. https://scikit-learn.org/stable/modules/model_evaluation.html

scikit-learn Developers. (2026b). *sklearn.neural_network.MLPClassifier*. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html

Distribución de fuentes: dos del material docente de la asignatura (Ruete, 2026a, 2026b), dos de documentación técnica oficial del software utilizado (scikit-learn Developers, 2026a, 2026b) y dos académicas complementarias (Pedregosa et al., 2011; Goodfellow et al., 2016), cumpliendo el mínimo de cinco fuentes distribuidas en las tres categorías solicitadas. Todas las fuentes listadas se citan en el desarrollo del informe.

XII. Anexos

Anexo A. Fragmentos de código fuente

Los siguientes fragmentos sintetizan las secciones del notebook que producen las evidencias principales del informe. El notebook completo, con sus salidas de ejecución, se encuentra en el repositorio del proyecto (sección IV).

Selección y codificación de variables

```
orden_educacion = {"High School": 1, "Bachelor's": 2, "Master's": 3, "PhD": 4}
df["Education_Level_Num"] = df["Education_Level"].map(orden_educacion)
job_title_dummies = pd.get_dummies(df["Job_Title"], prefix="Job_Title",
drop_first=True).astype(int)
X = pd.concat([df[variables_numericas], job_title_dummies], axis=1)
y = df["Risk_Category"]
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42, stratify=y)
scaler = StandardScaler().fit(X_train)
X_train_scaled = scaler.transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Arquitecturas de red neuronal evaluadas

```
MLPClassifier(hidden_layer_sizes=(32,), activation="relu", solver="adam",
alpha=0.001, max_iter=1000, random_state=42, early_stopping=True)
MLPClassifier(hidden_layer_sizes=(32, 16), activation="relu", solver="adam",
alpha=0.001, max_iter=1000, random_state=42, early_stopping=True)
MLPClassifier(hidden_layer_sizes=(32, 16, 8), activation="relu", solver="adam",
alpha=0.001, max_iter=1000, random_state=42, early_stopping=True)
```

Anexo B. Distribución de Risk_Category por Job_Title

Se presenta la tabla cruzada que sustenta el análisis de la sección 3.2 y la Figura 2, con la proporción de cada clase de riesgo dentro de cada cargo y el número de observaciones por cargo. Los cargos se agrupan según su clase de riesgo dominante para facilitar la lectura.

Job_Title	n	Low	Medium	High
AI Engineer	140	1,000	0,000	0,000
Doctor	132	1,000	0,000	0,000
Nurse	142	1,000	0,000	0,000
Research Scientist	149	1,000	0,000	0,000
Teacher	166	1,000	0,000	0,000
Chef	141	0,000	1,000	0,000
Mechanic	136	0,000	1,000	0,000
UX Researcher	167	0,000	1,000	0,000
Data Scientist	167	0,006	0,994	0,000
Graphic Designer	160	0,006	0,994	0,000
Financial Analyst	151	0,007	0,993	0,000
Marketing Manager	134	0,007	0,993	0,000
Lawyer	132	0,008	0,992	0,000
HR Specialist	157	0,013	0,987	0,000
Software Engineer	175	0,017	0,983	0,000
Customer Support	133	0,000	0,000	1,000
Security Guard	154	0,000	0,013	0,987
Construction Worker	156	0,000	0,019	0,981
Retail Worker	155	0,000	0,019	0,981
Truck Driver	153	0,000	0,020	0,980

Tabla 19. Proporción de cada clase de Risk_Category dentro de cada Job_Title (dataset completo, n = 3.000).

Ningún cargo distribuye sus observaciones entre las tres clases de riesgo: en los veinte casos, una única clase concentra al menos el 98% de los registros. Esta es la evidencia cuantitativa que sustenta la afirmación de que Job_Title opera como un identificador casi determinístico de Risk_Category (secciones 3.2 y IX).

Anexo C. Reporte de clasificación por clase de las tres arquitecturas

El reporte tabulado de la sección VIII consolida las métricas macro-promediadas. Se incorpora aquí el desglose por clase generado con classification_report sobre el conjunto de prueba, que permite verificar el comportamiento individual de Low, Medium y High en cada arquitectura.

Modelo	Clase	Precision	Recall	F1-score	Soporte
MLP 1 capa oculta	Low	1,0000	1,0000	1,0000	148
MLP 1 capa oculta	Medium	1,0000	0,9868	0,9934	304
MLP 1 capa oculta	High	0,9737	1,0000	0,9867	148
MLP 2 capas ocultas	Low	1,0000	0,9730	0,9863	148
MLP 2 capas ocultas	Medium	0,9934	0,9868	0,9901	304
MLP 2 capas ocultas	High	0,9610	1,0000	0,9801	148
MLP 3 capas ocultas	Low	0,9933	1,0000	0,9966	148
MLP 3 capas ocultas	Medium	1,0000	0,9836	0,9917	304
MLP 3 capas ocultas	High	0,9737	1,0000	0,9867	148

Tabla 20. Reporte de clasificación por clase de las tres arquitecturas, calculado sobre el conjunto de prueba (600 observaciones).

El desglose muestra que las tres arquitecturas alcanzan recall igual a 1,0000 en la clase High: ninguna observación de riesgo alto queda sin identificar. La precisión en esa misma clase es la métrica más baja de los tres modelos (0,9610 a 0,9737), porque los escasos errores existentes consisten en observaciones de otras clases clasificadas como High. Para NextWork Advisory este comportamiento es preferible al inverso, ya que el costo de no detectar un cargo de riesgo alto es mayor que el de revisar manualmente un falso positivo.

Anexo D. Curvas de pérdida comparadas de las tres arquitecturas

Las curvas de pérdida individuales se presentan en las Figuras 3, 4 y 5 junto a sus respectivas matrices de confusión. Se incorpora aquí su superposición en un mismo sistema de ejes, que permite comparar directamente la velocidad de convergencia y el punto de detención por early stopping de las tres arquitecturas.




Figura 7. Curvas de pérdida de las tres arquitecturas evaluadas, con indicación del punto de detención por *early stopping*.

Las tres curvas decrecen de forma monótona y estable, sin oscilaciones que sugieran inestabilidad en el entrenamiento. Las arquitecturas más profundas alcanzan valores de pérdida ligeramente menores y detienen el ajuste antes (23 y 27 iteraciones frente a 40), lo que confirma que convergen más rápido sobre el conjunto de validación interno. Sin embargo, esa convergencia más temprana no se traduce en un mejor desempeño sobre el conjunto de prueba (sección VIII), lo que refuerza la conclusión de la sección IX.

Anexo E. Checklist de alineación con la rúbrica

Criterio de rúbrica	Evidencia incluida en el informe	Estado
C1 Datos y preparación para redes neuronales	Sección II: descripción, variable objetivo, predictoras, selección y partición.	Incluido
C2 Análisis exploratorio inicial	Sección III: distribución de clases, relación Job Title–Risk Category.	Incluido
C3 MLP una capa oculta	Sección V: arquitectura, parámetros, ejecución, resultados e interpretación.	Incluido
C4 MLP dos capas ocultas	Sección VI: arquitectura, parámetros, ejecución, resultados e interpretación.	Incluido
C5 MLP tres capas ocultas	Sección VII: arquitectura, parámetros, ejecución, resultados e interpretación.	Incluido
C6 Evaluación de desempeño	Sección VIII: matrices de confusión, métricas y reporte tabulado.	Incluido
C7 Comparación de arquitecturas	Sección IX: reporte comparativo, mejor desempeño y conclusión preliminar.	Incluido
C8 Notebook y documentación	Sección IV: trazabilidad notebook-informe-repositorio.	Incluido
C9 Conclusiones	Sección X: síntesis, conclusiones	Incluido

	comparativas e implicancias.	
C10 Portada e índice	Portada: curso, integrantes, fecha e índice numerado.	Incluido
C11 Formato institucional	Documento en tamaño carta, tipografía Arial 11, estructura jerárquica.	Incluido
C12 Ortografía y gramática	Redacción revisada en todas las secciones.	Incluido
C13 Fuentes, citación y referencias	Sección XI: 6 fuentes en formato APA 7. ^a edición, todas citadas en el desarrollo.	Incluido
C14 Anexos	Sección XII: tabla derivada del análisis, reporte de clasificación por clase, visualización complementaria, código fuente y checklist.	Incluido

Tabla 21. Checklist de cumplimiento de la rúbrica.