

MCDI505 — Análisis de Series de Tiempo

Sumativa 1 · Informe de análisis exploratorio de series de tiempo

Consumo eléctrico mensual del segmento comercial — Distribuidora Eléctrica del Litoral (DEL)

Autor: Roberto Moncada

Programa: Magíster en Ciencia de Datos · UNAB Online

Curso: MCDI505 — Análisis de Series de Tiempo · Unidad 1, Semana 1

Archivo: mcdi505_slrmoncada.ipynb · **Fecha:** septiembre de 2026

Resumen. Este informe caracteriza la serie mensual de consumo eléctrico del segmento comercial de DEL (2015-2023, 108 observaciones de entrenamiento). Mediante exploración gráfica, descomposición clásica y funciones de autocorrelación se identifican: una tendencia creciente que se estanca en 2018-2019, una estacionalidad anual intensa (fuerza $F_s = 0,90$) con máximo en enero y mínimo en mayo, un cambio de nivel potencial por la incorporación de clientes en abril de 2019, un shock exógeno por COVID-19 (efecto entre marzo de 2020 y enero de 2022) que implicó unos 195 GWh no consumidos entre marzo de 2020 y diciembre de 2021, un dato atípico en noviembre de 2017 y un residuo que conserva autocorrelación ($\rho_1 = 0,44$). La ACF muestra decaimiento lento y picos en los rezagos 12, 24, 36 y 48, por lo que la serie es no estacionaria y estacional. Se concluye que el modelamiento posterior debería considerar una transformación logarítmica, diferenciación estacional ($D = 1$) y regular probable ($d = 1$), y un tratamiento explícito del quiebre COVID.

Palabras clave: series de tiempo, estacionalidad, descomposición, ACF, PACF, consumo eléctrico.

Organización del informe. El documento sigue el orden de los criterios de la evaluación: (1) introducción y contexto, (2) configuración y preparación de los datos, (3) exploración y visualización, (4) descomposición de la serie, (5) análisis de autocorrelación, (6) interpretación técnica integrada, (7) conclusiones y (8) referencias. Cada decisión metodológica se expone con su evidencia, la alternativa descartada y su consecuencia.

1. Introducción y contexto del dataset

Distribuidora Eléctrica del Litoral (DEL) opera la red de distribución de comunas costeras y del interior de la Región de Valparaíso. Su segmento comercial (oficinas, comercio minorista, hotelería y servicios) representa cerca de un tercio de la energía distribuida y es el de mayor variabilidad estacional. Cada diciembre, DEL debe comprometer ante el Coordinador Eléctrico Nacional los volúmenes de energía que contratará mes a mes para el año siguiente. El costo del error es asimétrico: subestimar obliga a comprar en el mercado *spot* a precios de dos a cuatro veces el contratado,

mientras que sobreestimar implica pagar energía no consumida y sin posibilidad de reventa.

La pregunta de negocio del proyecto es cuál será el consumo mensual esperado de los próximos doce meses, con qué incertidumbre y qué volumen conviene contratar. Este informe corresponde a la primera etapa de ese proyecto y su propósito es **comprender la estructura temporal de la serie** antes de modelarla: identificar sus componentes (tendencia, estacionalidad, ciclo y error) y relacionar los patrones observados con las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF). No se construye aquí ningún modelo de pronóstico.

Datos. El conjunto `consumo_electrico_litoral.csv` contiene 120 observaciones mensuales (enero de 2015 a diciembre de 2024) y cuatro variables: el consumo facturado (`consumo_gwh`, variable objetivo, en GWh), los empalmes comerciales activos (`clientes_comerciales`), la temperatura media mensual (`temperatura_media_c`) y los días hábiles del mes (`dias_habiles`). Los datos son sintéticos, generados para reproducir la estructura de una serie real de consumo comercial (Universidad Andrés Bello, s. f.). El periodo estacional es $s = 12$.

Partición y sellado. Siguiendo el protocolo del curso, el análisis utiliza únicamente el periodo **2015-01 a 2023-12 (108 observaciones)**. El año 2024 constituye el conjunto de prueba y permanece sellado: se excluye en la carga de datos y no interviene en ningún cálculo ni gráfico de este informe. Evitar el uso de información posterior al corte es necesario para no invalidar la evaluación final del modelo (Tashman, 2000).

Hechos relevantes del periodo (no están marcados en los datos y fueron contrastados con ellos): la incorporación de unos 900 clientes comerciales por la apertura de un centro comercial en abril de 2019, las restricciones sanitarias por COVID-19 entre marzo de 2020 y diciembre de 2021, y una recalibración de medidores en noviembre de 2017 que produjo un registro anómalo puntual.

Enfoque. La serie objetivo es univariada; el conjunto de datos es multivariado. Las covariables se usan aquí con fines exploratorios y explicativos (sección 3.5), no como insumo de un modelo.

2. Configuración y preparación de los datos

Esta sección deja el notebook reproducible de principio a fin (semilla fija, rutas relativas, sin modificar el archivo original) y verifica la integridad estructural de la serie. Todo el código está comentado para facilitar su auditoría. El análisis se realiza con `pandas`, `matplotlib` y `statsmodels` (Seabold y Perktold, 2010).

```
# =====  
# 2.1 Librerías y configuración general  
# =====  
import warnings  
from pathlib import Path  
  
import numpy as np  
import pandas as pd  
import matplotlib.pyplot as plt  
import statsmodels
```

```

from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.tsa.stattools import acf, pacf
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

warnings.filterwarnings("ignore")
np.random.seed(505) # semilla fija (reproducibilidad)

# Paleta sobria y consistente en todo el informe
ROJO, AZUL, VERDE, GRIS, NEGRO = "#b30338", "#0057b8", "#2e7d32", "#9e9e9e", "#222222"
plt.rcParams.update({
    "figure.figsize": (11, 3.8), "figure.dpi": 100,
    "axes.grid": True, "grid.alpha": 0.25,
    "axes.spines.top": False, "axes.spines.right": False,
    "axes.titlesize": 11, "axes.labelsize": 9.5, "font.size": 9,
})

# Hitos del caso (contexto entregado en el documento base del curso)
COVID_INI, COVID_FIN = pd.Timestamp("2020-03-01"), pd.Timestamp("2021-12-01")
CLIENTES = pd.Timestamp("2019-04-01") # incorporación de ~900 clientes comerciales
MEDIDORES = pd.Timestamp("2017-11-01") # recalibración de medidores (atípico)
print("pandas", pd.__version__, "· numpy", np.__version__)

```

pandas 3.0.2 · numpy 2.4.4

```

# =====
# 2.2 Carga de datos (ruta relativa) y SELLADO del conjunto de prueba
# =====
ARCHIVO = "consumo_electrico_litoral.csv"
ruta = next(p for p in [Path(ARCHIVO), Path("datos") / ARCHIVO, Path("../") / "datos" / ARCHIVO]
             if p.exists())

# asfreq("MS") fuerza el calendario mensual: un mes ausente quedaría como NaN
df_total = pd.read_csv(ruta, parse_dates=["fecha"]).set_index("fecha").asfreq("MS")

# Partición cronológica: 2015-01 a 2023-12 (entrenamiento) | 2024 (prueba sellada).
# A partir de esta línea NO se vuelve a usar el año 2024 en ningún cálculo ni gráfico.
CORTE = "2023-12-31"
df = df_total.loc[:CORTE].copy()
del df_total

print(f"Archivo: {ruta}")
print(f"Periodo analizado: {df.index.min():%Y-%m} a {df.index.max():%Y-%m} "
      f"({len(df)} observaciones = {len(df)//12} años completos)")
display(df.head())

```

Archivo: consumo_electrico_litoral.csv
 Periodo analizado: 2015-01 a 2023-12 (108 observaciones = 9 años completos)

	consumo_gwh	clientes_comerciales	temperatura_media_c	dias_habiles
fecha				
2015-01-01	108.32	41827	19.6	22
2015-02-01	94.71	41918	18.7	20
2015-03-01	89.52	42045	16.5	22
2015-04-01	82.24	42129	13.3	22
2015-05-01	82.60	42242	12.0	21

```

# =====
# 2.3 Ficha técnica y auditoría de integridad
# =====

```

```

print("Frecuencia del índice :", df.index.freqstr)
print("Índice ordenado      :", df.index.is_monotonic_increasing)
print("Índice sin duplicados :", df.index.is_unique)
completo = pd.date_range(df.index.min(), df.index.max(), freq="MS")
print("Calendario completo  :", df.index.equals(completo))
print("Consumo <= 0        :", int((df["consumo_gwh"] <= 0).sum()))
print("Nulos en consumo    :", df["consumo_gwh"].isna().sum(),
      list(df.index[df["consumo_gwh"].isna()].strftime("%Y-%m")))

display(df.describe().T.round(2))

```

```

Frecuencia del índice : MS
Índice ordenado      : True
Índice sin duplicados : True
Calendario completo  : True
Consumo <= 0        : 0
Nulos en consumo     : 3 ['2016-08', '2019-02', '2022-06']

```

	count	mean	std	min	25%	50%	75%	max
consumo_gwh	105.0	102.85	12.67	73.19	94.71	101.31	111.08	133.58
clientes_comerciales	108.0	48634.68	4191.69	41827.00	44891.75	48952.50	52340.75	55436.00
temperatura_media_c	108.0	15.59	3.20	10.50	12.50	15.30	18.40	21.70
dias_habiles	108.0	21.73	0.94	20.00	21.00	22.00	22.00	23.00

Lectura de la auditoría. El índice es estrictamente creciente, sin duplicados y coincide con el calendario mensual completo (MS), de modo que el espaciado es regular en la escala en que opera el análisis. No existen valores no positivos. La única anomalía estructural son **tres valores faltantes** en consumo_gwh (agosto de 2016, febrero de 2019 y junio de 2022), equivalentes a un 2,8 % de las 108 observaciones, atribuibles a fallas de telemetría. En el periodo analizado el consumo promedia 102,85 GWh (desviación estándar 12,67 GWh), con un mínimo de 73,19 GWh y un máximo de 133,58 GWh.

```

# =====
# 2.4 Valores faltantes: comparación de estrategias y decisión
# =====
s = df["consumo_gwh"]
huecos = s[s.isna()].index

estrategias = {
    "lineal": s.interpolate("linear"),
    "temporal": s.interpolate("time"),
    # mismo mes del año previo, escalado por la razón entre el mes anterior y su par del año previo
    "estacional": s.fillna(s.shift(12) * (s.shift(1) / s.shift(13))),
}

comp = pd.DataFrame({k: v.loc[huecos] for k, v in estrategias.items()}).round(2)
comp.insert(0, "mes", huecos.month)
comp["máx-mín"] = (comp[["lineal", "temporal", "estacional"]].max(axis=1)
                  - comp[["lineal", "temporal", "estacional"]].min(axis=1)).round(2)
display(comp)

# Decisión: interpolación temporal para los tres huecos (ver justificación en el texto)
y = s.interpolate("time")
y.name = "consumo_gwh"

# Impacto de la decisión sobre media, desviación estándar y autocorrelación de orden 1
impacto = pd.DataFrame({
    k: {"media": v.mean(), "desv. estándar": v.std(), "ACF(1)": v.autocorr(1)}
    for k, v in {"lineal": estrategias["lineal"], "temporal": estrategias["temporal"]}.items()
})

```

```
}).T
display(impacto.round(4))
```

	mes	lineal	temporal	estacional	máx-mín
fecha					
2016-08-01	8	95.86	95.86	94.87	0.99
2019-02-01	2	116.93	116.34	114.18	2.75
2022-06-01	6	101.40	101.43	103.86	2.46

	media	desv. estándar	ACF(1)
lineal	102.9001	12.5828	0.7672
temporal	102.8950	12.5768	0.7670

Decisión 1 — Imputación de los valores faltantes


Elemento	Detalle
Decisión	Imputar los tres huecos por interpolación temporal (<code>interpolate("time")</code>).
Evidencia	Los huecos caen en meses de comportamiento distinto: agosto (2016) está en la zona plana invernal del perfil estacional (índice 0,96); febrero (2019) está en el tramo de descenso desde el máximo de enero (1,21) hacia marzo (1,01); junio (2022) está en el valle, cerca del mínimo de mayo (0,89). Las tres estrategias comparadas difieren en 0,99, 2,75 y 2,46 GWh respectivamente (máximo 2,4 % del nivel). En los tres casos los dos meses vecinos existen y son observaciones reales.
Alternativa descartada	La imputación estacional (mismo mes del año previo ajustado) depende de un único valor del año anterior, que arrastra su propio ruido; además, en junio de 2022 el mes base (junio de 2021) pertenece al periodo de recuperación del COVID, con una variación interanual de +19,5 %, por lo que el método propagaría la distorsión del shock.
Consecuencia	El impacto sobre los estadísticos es despreciable: la media pasa de 102,900 (lineal) a 102,895 GWh (temporal), la desviación estándar de 12,583 a 12,577 GWh y la ACF(1) de 0,7672 a 0,7670. Aun así, se declara que 3 de 108 observaciones son imputadas, porque una serie imputada presenta autocorrelación artificial en los rezagos vecinos al hueco.

3. Exploración y visualización de la serie

3.1 Serie completa

```
# =====
# 3.1 Serie completa con hitos y valores imputados
# =====
```

```
fig, ax = plt.subplots(figsize=(11.5, 4.2))
ax.plot(y.index, y.values, color=R0J0, lw=1.4, label="consumo mensual (GWh)")
ax.plot(huecos, y.loc[huecos], "o", color=AZUL, ms=6, zorder=5, label="valores imputados")
ax.axvspan(COVID_INI, COVID_FIN, color=GRIS, alpha=0.25, label="periodo COVID-19")
ax.axvline(CLIENTES, color=VERDE, ls="--", lw=1.2, label="incorporación de clientes (abr-2019)")
ax.axvline(MEDIDORES, color=NEGRO, ls=":", lw=1.4, label="recalibración de medidores (nov-2017)")
ax.set_ylabel("GWh"); ax.set_xlabel("fecha")
ax.set_title("Figura 1. Consumo mensual del segmento comercial, DEL (2015-2023)")
ax.legend(fontsize=8, ncol=3, loc="upper center", bbox_to_anchor=(0.5, -0.16), frameon=False)
plt.tight_layout(); plt.show()
```



Descripción (Figura 1). La serie muestra un claro **patrón estacional anual** que se repite de forma casi idéntica: picos pronunciados en el verano austral (diciembre-enero) y valles en otoño (abril-mayo), con un pico secundario más suave en invierno. Sobre ese patrón se distinguen cuatro rasgos:

1. Una **tendencia creciente** entre 2015 y 2018: el consumo medio anual pasa de 90,8 GWh (2015) a 107,1 GWh (2018).
2. Un **estancamiento en 2018-2019** (107,1 y 107,2 GWh de media anual), a pesar de que los clientes comerciales siguen creciendo.
3. Una **caída abrupta desde marzo de 2020**, que lleva el consumo a su mínimo histórico de 73,2 GWh en mayo de 2020 (el mes más bajo de la serie, cuando lo esperable para mayo era cercano a 97 GWh), seguida de una recuperación gradual durante 2021 y una normalización en 2022. La media anual de 2020 (95,5 GWh) es 11 % inferior a la de 2019.
4. Un **máximo aislado** en noviembre de 2017, que se examina en la sección siguiente.

La variabilidad alrededor del nivel no cambia de forma evidente a simple vista, salvo durante el periodo COVID, en que la amplitud de las oscilaciones aumenta por el hundimiento de los meses de otoño-invierno de 2020. No se observa un cambio de nivel visible en abril de 2019, lo que se discute en la sección 3.5.

3.2 Variación interanual y dato atípico de noviembre de 2017

```
# =====
# 3.2 Variación interanual y aislamiento del atípico de 2017-11
# =====
yoy = (y / y.shift(12) - 1) * 100 # % respecto del mismo mes del año anterior

fig, axes = plt.subplots(1, 2, figsize=(12, 3.8), gridspec_kw={"width_ratios": [1.5, 1]})
axes[0].plot(yoy.index, yoy.values, color="#455a64", lw=1.2)
```

```

axes[0].axhline(0, color="k", lw=0.8)
axes[0].axvspan(COVID_INI, COVID_FIN, color=GRIS, alpha=0.25)
axes[0].annotate("2017-11", (MEDIDORES, yoy.loc[MEDIDORES]), xytext=(-55, 12),
                  textcoords="offset points", fontsize=8, arrowprops=dict(arrowstyle="-", lw=0.6))
axes[0].set_ylabel("% var. interanual")
axes[0].set_title("Figura 2a. Variación interanual del consumo")

# 2016, 2017 y 2018 superpuestos para aislar el dato de noviembre de 2017
for anio, col, lw in [(2016, GRIS, 1.2), (2017, ROJO, 1.8), (2018, AZUL, 1.2)]:
    g = y[str(anio)]
    axes[1].plot(g.index.month, g.values, color=col, lw=lw, marker="o", ms=3, label=str(anio))
axes[1].set_xticks(range(1, 13)); axes[1].set_xlabel("mes"); axes[1].set_ylabel("GWh")
axes[1].set_title("Figura 2b. Años 2016-2018 superpuestos"); axes[1].legend(fontsize=8)
plt.tight_layout(); plt.show()

# z robusto del componente irregular (mismo procedimiento que la auditoría del curso):
# 1) nivel = media móvil centrada 2x12; 2) razón serie/nivel; 3) dividir por la mediana del mes
nivel = y.rolling(12, center=True).mean().rolling(2, center=True).mean().shift(-1)
razon = (y / nivel).dropna()
irregular = razon / razon.groupby(razon.index.month).transform("median")
mad = (irregular - irregular.median()).abs().median()
z = (irregular - irregular.median()) / (1.4826 * mad)
candidatos = z[z.abs() > 3.5].round(2)
print("Candidatos a atípico (|z robusto| > 3,5):")
print(candidatos.rename("z").to_string())
print(f"\nNoviembre de 2017: {y.loc[MEDIDORES]:.2f} GWh | octubre: {y.loc['2017-10-01']:.2f} | "
      f"diciembre: {y.loc['2017-12-01']:.2f} | nov-2016: {y.loc['2016-11-01']:.2f} | nov-2018: "
      f"{y.loc['2018-11-01']:.2f}")

# Efecto de reemplazar el dato por su valor esperado (nivel x razón mediana de noviembre)
esperado = nivel.loc[MEDIDORES] * razon.groupby(razon.index.month).median().loc[11]
y_aj = y.copy(); y_aj.loc[MEDIDORES] = esperado
print(f"Valor esperado para nov-2017: {esperado:.2f} GWh (exceso observado: {y.loc[MEDIDORES] - "
      f"esperado:+.2f} GWh)")
print(f"Efecto de ajustarlo -> media: {y.mean():.3f} vs {y_aj.mean():.3f} | desv. estándar: "
      f"{y.std():.3f} vs {y_aj.std():.3f}")
print(f"Variación interanual de nov-2017: {yoy.loc[MEDIDORES]:+.1f}% | de nov-2018: "
      f"{yoy.loc['2018-11-01']:+.1f}%")

```

Candidatos a atípico (|z robusto| > 3,5):


fecha	
2017-11-01	4.10
2019-10-01	3.56
2020-02-01	3.81
2020-04-01	-5.27
2020-05-01	-7.56
2020-06-01	-5.27

Noviembre de 2017: 118.96 GWh | octubre: 95.74 | diciembre: 119.97 | nov-2016: 104.56 | nov-2018: 117.25

Valor esperado para nov-2017: 109.86 GWh (exceso observado: +9.10 GWh)

Efecto de ajustarlo -> media: 102.895 vs 102.811 | desv. estándar: 12.577 vs 12.498

Variación interanual de nov-2017: +13.8% | de nov-2018: -1.4%



Descripción (Figuras 2a y 2b). Entre 2016 y 2019 la variación interanual tiene un promedio de +4,4 % (rango de -7,7 % a +13,8 %), lo que confirma un crecimiento moderado hasta 2018 y su desaceleración posterior. Destacan dos episodios: el dato de **noviembre de 2017** (+13,8 %, el máximo del periodo previo al COVID, aunque de magnitud similar a febrero de 2016, +13,5 %, de modo que lo distintivo no es su variación interanual sino que rompe el patrón estacional) y el shock de 2020-2021. La caída de 2020 alcanza un -23,9 % en mayo y el rebote de abril a junio de 2021 (+17 % a +26 %) es un **efecto base**: compara meses recuperados con los meses hundidos de 2020 y no indica un crecimiento real del consumo.

La superposición de 2016-2018 (Figura 2b) muestra que noviembre de 2017 (118,96 GWh) se separa del patrón de los demás años: el consumo de octubre fue de 95,74 GWh y el de diciembre de 119,97 GWh, de modo que el salto de octubre a noviembre (+24 %) es casi el doble del habitual (+13,6 %). El procedimiento de z robusto sobre el componente irregular lo marca con $z = +4,10$, por encima del umbral de 3,5. Se detectan además otros candidatos: 2019-10 ($z = 3,56$) y 2020-02 ($z = 3,81$), valores marginales sin hecho documentado que los explique y compatibles con la cola del ruido; y abril, mayo y junio de 2020 ($z = -5,27; -7,56; -5,27$), que corresponden al shock COVID y no a errores de medición.

Decisión 2 — Tratamiento del atípico de noviembre de 2017

Elemento	Detalle
Decisión	Conservar el dato en esta etapa exploratoria, marcarlo y anticipar su reemplazo por el valor esperado antes del modelamiento.
Evidencia	Exceso de +9,10 GWh sobre el valor esperado de 109,86 GWh (un 8,3 % por encima). Operaciones confirmó que se trata de una recalibración de medidores y no de consumo real. Su efecto global es pequeño: ajustarlo cambia la media de 102,895 a 102,811 GWh y la desviación estándar de 12,577 a 12,498 GWh.
Alternativa descartada	Eliminarlo u ocultarlo sin registro: rompería la regularidad del índice y borraría trazabilidad. Dejarlo sin marcar tampoco es adecuado, porque, al ser un error de medición y no una característica del proceso, introduciría ruido espurio en la ACF y en la estimación.

Elemento	Detalle
Consecuencia	En la descomposición aparecerá como uno de los mayores residuos positivos (+7,0 %). Dado que el hecho está confirmado como error de medición, en las semanas siguientes se recomienda tratarlo como valor faltante (interpolación o imputación estacional) o con una variable indicadora de intervención.

3.3 Patrón estacional y su relación con la temperatura

```
# =====
# 3.3 Patrón estacional: perfil promedio, superposición anual y temperatura
# =====
perfil = y.groupby(y.index.month).mean() / y.mean() # índice estacional simple
temp_mes = df["temperatura_media_c"].groupby(df.index.month).mean()


fig, axes = plt.subplots(1, 3, figsize=(13, 3.8))
axes[0].bar(perfil.index, perfil.values, color=R0J0, alpha=0.85)
axes[0].axhline(1, color="k", lw=0.9)
axes[0].set_xticks(range(1, 13)); axes[0].set_xlabel("mes"); axes[0].set_ylabel("índice (media = 1)")
axes[0].set_title("Figura 3a. Perfil estacional promedio")

for anio, g in y.groupby(y.index.year):
    especial = anio in (2020, 2023)
    axes[1].plot(g.index.month, g.values, lw=1.8 if especial else 0.9,
                 color={2020: AZUL, 2023: R0J0}.get(anio, "#cccccc"),
                 label=str(anio) if especial else None)
axes[1].set_xticks(range(1, 13)); axes[1].set_xlabel("mes"); axes[1].set_ylabel("GWh")
axes[1].set_title("Figura 3b. Superposición anual (2020 y 2023 destacados)")
axes[1].legend(fontsize=8)

axes[2].plot(perfil.index, perfil.values, "o-", color=R0J0, label="índice estacional del consumo")
ax2 = axes[2].twinx()
ax2.plot(temp_mes.index, temp_mes.values, "s--", color=AZUL, label="temperatura media (°C)")
ax2.grid(False); ax2.spines["right"].set_visible(True)
axes[2].set_xticks(range(1, 13)); axes[2].set_xlabel("mes")
axes[2].set_ylabel("índice"); ax2.set_ylabel("°C")
axes[2].set_title("Figura 3c. Consumo vs. temperatura por mes")
plt.tight_layout(); plt.show()

print("Índice estacional por mes:", dict(zip(perfil.index, perfil.round(3))))
print("Temperatura media por mes:", dict(zip(temp_mes.index, temp_mes.round(1))))
print("Correlación mensual perfil-temperatura: "
      f"{np.corrcoef(perfil.values, temp_mes.values)[0, 1]:+.2f}")
```

```
Índice estacional por mes: {1: 1.19, 2: 1.081, 3: 1.0, 4: 0.892, 5: 0.89, 6: 0.933, 7: 0.974, 8:
0.959, 9: 0.922, 10: 0.93, 11: 1.056, 12: 1.173}
Temperatura media por mes: {1: 20.1, 2: 19.4, 3: 17.6, 4: 15.3, 5: 13.6, 6: 11.7, 7: 11.3, 8: 12.1,
9: 13.6, 10: 15.2, 11: 17.9, 12: 19.4}
Correlación mensual perfil-temperatura: +0.80
```



Descripción (Figuras 3a-3c). El perfil estacional promedio muestra un **máximo en enero** (índice 1,19 respecto de la media), un segundo nivel alto en diciembre (1,17) y febrero (1,08), un **mínimo en abril-mayo** (0,89) y una recuperación moderada en **julio** (0,97), que supera a junio (0,93) y agosto (0,96) y configura un máximo local invernal. El consumo de enero es cerca de un 34 % superior al de mayo. La superposición anual (Figura 3b) confirma que este perfil se repite año tras año con pequeñas variaciones de intensidad, y que 2020 (en azul) rompe el patrón entre abril y octubre.

Mecanismo de la doble estacionalidad. La temperatura media mensual es máxima en enero (20,1 °C) y mínima en julio (11,3 °C). El consumo no sigue una relación monótona con ella: sube tanto con el calor intenso (refrigeración, mayor actividad turística y comercial estival en comunas costeras, hipótesis coherente con el rubro hotelero) como, en menor medida, con el frío (calefacción). Por tramos de temperatura, el consumo medio es de 97,1 GWh con 12 °C o menos, baja a 95,0 y 95,3 GWh entre 12 y 16 °C y sube a 100,1 GWh entre 16 y 18 °C y a 116,8 GWh sobre 18 °C. La relación es, por tanto, en forma de U asimétrica: el frío eleva el consumo un 2 % por sobre el mínimo, mientras que el calor lo eleva cerca de un 23 %. Por esa asimetría, el máximo estival domina el perfil y el invernal es solo un repunte local.

3.4 Estabilidad de la media y de la varianza

```
# =====
# 3.4 Nivel y dispersión: media/desv. móviles y amplitud estacional por año
# =====

fig, axes = plt.subplots(1, 2, figsize=(12, 3.6))
rm, rs = y.rolling(12).mean(), y.rolling(12).std()
axes[0].plot(rm, color=R0J0, label="media móvil 12 m")
axes[0].plot(rs, color=AZUL, label="desv. estándar móvil 12 m")
axes[0].axvspan(COVID_INI, COVID_FIN, color=GRIS, alpha=0.25)
axes[0].set_ylabel("GWh"); axes[0].legend(fontsize=8)
axes[0].set_title("Figura 4a. Media y dispersión móviles")

amp = pd.DataFrame({"media anual (GWh)": y.groupby(y.index.year).mean(),
                    "amplitud pico-valle (GWh)": y.groupby(y.index.year).max() -
                    y.groupby(y.index.year).min()})
amp["amplitud relativa (%)"] = 100 * amp.iloc[:, 1] / amp.iloc[:, 0]
amp["CV intra-anual"] = y.groupby(y.index.year).std() / y.groupby(y.index.year).mean()
amp.index.name = "año"
axes[1].bar(amp.index, amp["amplitud relativa (%)"], color=[GRIS if a in (2020, 2021) else R0J0 for
a in amp.index])
axes[1].set_ylabel("% de la media anual"); axes[1].set_xlabel("año")
axes[1].set_title("Figura 4b. Amplitud estacional relativa (2020-2021 en gris)")
plt.tight_layout(); plt.show()
display(amp.round(2))
```

```

normales = amp.drop(index=[2020, 2021])
print("Excluyendo 2020-2021: amplitud absoluta "
      f"{normales.iloc[0, 1]:.1f} -> {normales.iloc[-1, 1]:.1f} GWh; relativa "
      f"{normales.iloc[0, 2]:.1f}% -> {normales.iloc[-1, 2]:.1f}% "
      f"(desv. estándar de la relativa: {normales.iloc[:, 2].std():.2f} pp)")
# Elasticidad de la dispersión respecto del nivel (años sin COVID): 0 = aditivo puro, 1 =
multiplicativo puro
lm = np.log(y.groupby(y.index.year).mean().drop(index=[2020, 2021]))
ls = np.log(y.groupby(y.index.year).std().drop(index=[2020, 2021]))
print(f"Elasticidad de la desv. estándar anual respecto de la media anual: {np.polyfit(lm, ls, 1)
[0]:.2f}")
print("Correlación media móvil-desv. móvil antes de COVID (2015-2019): "
      f"{np.corrcoef(rm[:'2019-12'].dropna(), rs[:'2019-12'].dropna())[0, 1]:+.2f}")



```

Excluyendo 2020-2021: amplitud absoluta 28.8 -> 34.1 GWh; relativa 31.8% -> 30.0% (desv. estándar de la relativa: 3.76 pp)

Elasticidad de la desv. estándar anual respecto de la media anual: 0.31

Correlación media móvil-desv. móvil antes de COVID (2015-2019): +0.43

	media anual (GWh)	amplitud pico-valor (GWh)	amplitud relativa (%)	CV intra-anual
año				
2015	90.78	28.84	31.77	0.11
2016	99.18	30.11	30.36	0.10
2017	103.39	31.01	29.99	0.11
2018	107.09	37.59	35.10	0.11
2019	107.21	32.18	30.02	0.09
2020	95.49	51.21	53.63	0.17
2021	102.15	32.19	31.51	0.10
2022	107.11	24.16	22.56	0.08
2023	113.66	34.05	29.96	0.09



Descripción (Figuras 4a y 4b). La media móvil de 12 meses crece de 90,8 GWh (diciembre de 2015) a 106,9 GWh (noviembre de 2018), cae durante el COVID y se recupera hasta 113,7 GWh al cierre de 2023: la **media no es constante**, lo que descarta la estacionariedad en media. La desviación estándar móvil, en cambio, se mantiene entre 8 y 13 GWh fuera del shock (llega a 17 GWh en 2020), sin una relación clara con el nivel (correlación de +0,43 con la media móvil antes del COVID). La amplitud estacional relativa se mantiene en torno al 30 % de la media anual (31,8 % en 2015 y 30,0 % en 2023, con 35,1 % en 2018) mientras que la absoluta crece de 28,8 a 34,1 GWh. Durante 2020 la amplitud relativa se dispara a 53,6 % por el shock.

Lectura. La evidencia sobre la forma de la estacionalidad es **mixta pero inclinada hacia un esquema multiplicativo**: la amplitud relativa estable ($\approx 30\%$) y la amplitud absoluta creciente apuntan a un efecto proporcional al nivel, pero la elasticidad de la dispersión anual respecto del nivel es de solo 0,31 (valor 1 sería multiplicativo puro y 0, aditivo puro) y la desviación móvil no crece con la media. La decisión definitiva entre ambos esquemas se fundamenta en la sección 4.

3.5 Relación con las covariables

```
# =====
# 3.5 Relación con las covariables (uso explicativo)
# =====
fig, axes = plt.subplots(1, 3, figsize=(12.5, 3.3))
for ax, var, etq in zip(axes, ["temperatura_media_c", "clientes_comerciales", "dias_habiles"],
                        ["Temperatura media (°C)", "Clientes comerciales", "Días hábiles"]):
    ax.scatter(df[var], y, s=16, alpha=0.6, color=R0J0)
    ax.set_xlabel(etq); ax.set_ylabel("consumo (GWh)")
    ax.set_title(f" $\rho = \{\text{np.corrcoef(df[var], y)[0, 1]:+.2f}\}$ ")
plt.suptitle("Figura 5. Consumo frente a las covariables", y=1.02, fontsize=11)
plt.tight_layout(); plt.show()

print("Correlaciones con el consumo:",
      {v: round(float(np.corrcoef(df[v], y)[0, 1]), 3) for v in ["temperatura_media_c",
                                                                "clientes_comerciales", "dias_habiles"]})
# Razón serie/nivel (estacionalidad + irregular) frente a la temperatura y a los días hábiles
rz = (y / y.rolling(12, center=True).mean().rolling(2, center=True).mean().shift(-1)).dropna()
print("Correlación de la razón serie/nivel con temperatura:", round(np.corrcoef(rz, df.loc[rz.index,
                                              "temperatura_media_c"])[0, 1], 3),
      "| con días hábiles:", round(np.corrcoef(rz, df.loc[rz.index, "dias_habiles"])[0, 1], 3))
# Clientes: salto puntual de abril de 2019
print("Clientes comerciales (mar, abr, may 2019):",
      df.loc["2019-03-01":"2019-05-01", "clientes_comerciales"].tolist())
print("Consumo medio por temperatura:")
print(y.groupby(pd.cut(df["temperatura_media_c"], [0, 12, 14, 16, 18,
25])).mean().round(1).to_string())
```

Correlaciones con el consumo: {'temperatura_media_c': 0.686, 'clientes_comerciales': 0.319, 'dias_habiles': 0.016}


Correlación de la razón serie/nivel con temperatura: 0.736 | con días hábiles: 0.033

Clientes comerciales (mar, abr, may 2019): [47561, 48620, 48720]

Consumo medio por temperatura:

temperatura_media_c	
(0, 12]	97.1
(12, 14]	95.0
(14, 16]	95.3
(16, 18]	100.1
(18, 25]	116.8

Figura 5. Consumo frente a las covariables



Descripción (Figura 5). La **temperatura** es la covariable más asociada al consumo ($\rho = +0,69$ lineal), y la relación es no monótona (en forma de U asimétrica), por lo que el coeficiente lineal subestima la dependencia real: la razón entre el consumo y su nivel (componente estacional e irregular) tiene $\rho = +0,74$ con la temperatura. Explica buena parte de la estacionalidad anual (correlación de $+0,80$ entre el perfil estacional y la temperatura mensual). Los **clientes comerciales** se relacionan débilmente ($\rho = +0,32$): su crecimiento es sostenido, de 42,4 mil a 54,8 mil empalmes (media anual de 2015 a 2023), mientras que el consumo se estanca en 2018-2019, de modo que cualquier correlación entre ambas series con tendencia debe tomarse con cautela por el riesgo de regresión espuria. En abril de 2019 los clientes saltan de 47.561 a 48.620 (+1.059 empalmes en un mes, unas diez veces el incremento mensual habitual de cerca de 100), coherente con la apertura del centro comercial, pero el consumo **no muestra un escalón visible** en ese mes (variación interanual de $-0,9\%$ en abril de 2019 y $+2,7\%$ a $+6,7\%$ de junio a septiembre), lo que sugiere que los nuevos clientes aportan poco consumo unitario o que su efecto se diluye en el ruido. Los **días hábiles** prácticamente no se correlacionan con el consumo ($\rho = +0,02$), porque su efecto, de existir, queda enmascarado por la estacionalidad, mucho mayor.

Enfoque elegido. Para este informe y para las semanas siguientes se adopta un enfoque **univariado** sobre consumo_gwh: la temperatura explica la estacionalidad pero su uso en pronóstico exige conocer sus valores futuros (que habría que proyectar con climatología, con la incertidumbre que eso añade), los clientes crecen con la tendencia y los días hábiles no muestran señal marginal.

3.6 Delimitación y magnitud del efecto COVID-19

```
# =====
# 3.6 Delimitación y magnitud del efecto COVID-19 (contrafactual simple)
# =====
# Contrafactual: promedio del mismo mes de 2018 y 2019 (nivel anual estable entre ambos años)
base = pd.concat([y["2018"], y["2019"]]).groupby(lambda f: f.month).mean()
contra = pd.Series(base.reindex(y.index.month).values, index=y.index)
brecha = (y / contra - 1) * 100

ventana = slice("2020-01-01", "2022-12-01")
print("Desviación % respecto del contrafactual (2020-2022):")
print(brecha[ventana].round(1).to_frame("desv. %").T.to_string())

w = slice(COVID_INI, COVID_FIN)
perdida = (contra[w] - y[w]).sum()
print(f"\nEnergía no consumida mar-2020 a dic-2021: {perdida:.1f} GWh "
      f"({100 * perdida / contra[w].sum():.1f}% de lo esperado)")
print(f"Mes de mayor caída: {brecha[w].idxmin():%Y-%m} ({brecha[w].min():.1f}%)")
bajo = brecha[COVID_INI:"2022-12-01"][brecha[COVID_INI:"2022-12-01"] < -3]
print(f"Último mes con desviación < -3%: {bajo.index.max():%Y-%m} -> retorno sostenido desde "
      f"{bajo.index.max() + pd.DateOffset(months=1):%Y-%m}")
```

```
Desviación % respecto del contrafactual (2020-2022):
fecha    2020-01-01  2020-02-01  2020-03-01  2020-04-01  2020-05-01  2020-06-01  2020-07-01  2020-
08-01  2020-09-01  2020-10-01  2020-11-01  2020-12-01  2021-01-01  2021-02-01  2021-03-01  2021-04-
01  2021-05-01  2021-06-01  2021-07-01  2021-08-01  2021-09-01  2021-10-01  2021-11-01  2021-12-01
2022-01-01  2022-02-01  2022-03-01  2022-04-01  2022-05-01  2022-06-01  2022-07-01  2022-08-01
2022-09-01  2022-10-01  2022-11-01  2022-12-01
desv. %      -3.8       -0.4       -8.4      -20.5      -24.4      -19.4      -13.4
-12.5      -8.5      -11.2      -11.5      -2.7       -4.6       -6.3       -3.5
```

-7.0	-4.9	-3.7	-1.1	-1.9	0.1	-10.4	-8.8	-3.6
-5.9	0.4	-0.8	0.2	2.6	1.5	-0.4	2.4	4.5
-2.6	-0.8	0.5						

Energía no consumida mar-2020 a dic-2021: 194.6 GWh (8.4% de lo esperado)

Mes de mayor caída: 2020-05 (-24.4%)

Último mes con desviación < -3%: 2022-01 -> retorno sostenido desde 2022-02

Descripción. Se usa como contrafactual el promedio del mismo mes de 2018 y 2019, dos años con nivel anual prácticamente idéntico (107,1 y 107,2 GWh), lo que evita extrapolar una tendencia que se había estancado. La desviación frente a ese contrafactual sitúa el **inicio del efecto en marzo de 2020** (-8,4 %; las desviaciones de enero y febrero, -3,8 % y -0,4 %, son menores), la **máxima caída en mayo de 2020** (-24,4 %) y una recuperación parcial hasta diciembre de 2020 (-2,7 %), con una recaída en octubre-noviembre de 2020 (-11,2 % y -11,5 %) y otra en octubre-noviembre de 2021 (-10,4 % y -8,8 %). Usando un criterio estricto (desviación mayor a -3 %), la **normalización sostenida se alcanza en febrero de 2022**, dos meses después del fin de las restricciones, y la ventana total del efecto es, por tanto, **marzo de 2020 a enero de 2022**. La energía no consumida entre marzo de 2020 y diciembre de 2021 es de **194,6 GWh**, un 8,4 % de lo esperado. Es una estimación conservadora, porque el contrafactual supone crecimiento nulo respecto de 2018-2019 cuando el crecimiento histórico de la tendencia fue de cerca de 2,8 % anual.

4. Descomposición de la serie e identificación de componentes

Se aplica la **descomposición clásica por medias móviles** (`seasonal_decompose`, período 12), que estima la tendencia-ciclo con una media móvil centrada 2×12 , promedia por mes la razón (o diferencia) entre la serie y esa tendencia para obtener un componente estacional fijo, y deja el residuo como error. Se escoge este método por su transparencia y por su relación directa con las preguntas de la evaluación; se discuten al final sus limitaciones y la alternativa STL (Cleveland et al., 1990).

Decisión 3 — Esquema aditivo o multiplicativo

```
# =====
# 4.1 Descomposición clásica: aditiva vs. multiplicativa
# =====
dec_add = seasonal_decompose(y, model="additive", period=12)
dec_mul = seasonal_decompose(y, model="multiplicative", period=12)

# Criterio de elección: un esquema es adecuado si su residuo es homogéneo respecto del nivel.
# Medimos la dispersión del residuo RELATIVA al nivel (tendencia) en el tramo sin COVID.
tramo = [(pd.Timestamp("2015-07-01"), pd.Timestamp("2019-12-01")),
         (pd.Timestamp("2022-01-01"), pd.Timestamp("2023-06-01"))]
def sin_covid(serie):
    return pd.concat([serie[a:b] for a, b in tramo]).dropna()

r_add = sin_covid(dec_add.resid / dec_add.trend * 100) # % del nivel
r_mul = sin_covid((dec_mul.resid - 1) * 100)           # % (ya es razón)
tabla_esq = pd.DataFrame({
    "aditivo": {"desv. residuo (% del nivel)": r_add.std(),
               "corr(|residuo|, nivel)": np.corrcoef(sin_covid(dec_add.resid).abs(),
sin_covid(dec_add.trend))[0, 1]},
    "multiplicativo": {"desv. residuo (% del nivel)": r_mul.std(),
```

```

"corr(|residuo|, nivel)": np.corrcoef(sin_covid(dec_mul.resid - 1).abs(),
sin_covid(dec_mul.trend))[0, 1]],
}).round(3)
display(tabla_esq)

```

	aditivo	multiplicativo
desv. residuo (% del nivel)	2.358	2.456
corr(residuo , nivel)	0.194	0.185

Elemento	Detalle
Decisión	Adoptar el esquema multiplicativo $y_t = T_t \times S_t \times R_t$ para el análisis de componentes.
Evidencia a favor	La amplitud estacional relativa es estable en torno al 30 % de la media anual entre 2015 y 2023 (31,8 % y 30,0 % en los extremos) mientras la absoluta crece de 28,8 a 34,1 GWh; el índice estacional tiene interpretación directa en porcentaje (enero +20,5 %, mayo -11,0 %); y la tendencia positiva (+2,8 % anual) eleva el nivel sobre el que actúa la estacionalidad. La descripción del caso también indica estacionalidad proporcional.
Evidencia en contra	La elasticidad de la dispersión respecto del nivel es 0,31 (intermedia), la desviación móvil no crece con la media y, como muestra la tabla, la dispersión del residuo es casi idéntica en ambos esquemas (2,36 % del nivel en el aditivo frente a 2,46 % en el multiplicativo) y la correlación entre residuo y nivel es similar (0,19 frente a 0,19). Es decir, los datos no rechazan con fuerza el esquema aditivo .
Alternativa descartada	Esquema aditivo: se mantiene como alternativa razonable, pero se prefiere el multiplicativo por la estabilidad de la amplitud relativa, por su interpretabilidad y porque es la base de la transformación logarítmica que probablemente se use en el modelamiento. STL queda pendiente para la etapa de modelamiento.
Consecuencia	Los componentes se leen en porcentaje del nivel. La elección se verificará formalmente en la Semana 2 comparando log y Box-Cox: la ambigüedad reconocida aquí es una limitación del análisis.

4.1 Componentes estimados

```

# =====
# 4.2 Componentes del esquema multiplicativo
# =====
fig, axes = plt.subplots(4, 1, figsize=(11.5, 9.5), sharex=True)
axes[0].plot(dec_mul.observed, color=NEGRO, lw=1.2); axes[0].set_ylabel("GWh")
axes[0].set_title("Figura 6. Descomposición multiplicativa (clásica, período 12)")
axes[0].text(0.01, 0.88, "Observada", transform=axes[0].transAxes, fontsize=9, color="#555555",
bbox=dict(facecolor="white", alpha=0.85, edgecolor="none"))
axes[1].plot(dec_mul.trend, color=ROJO, lw=1.6); axes[1].set_ylabel("GWh")


```

```

axes[1].axvspan(COVID_INI, COVID_FIN, color=GRIS, alpha=0.25)
axes[1].text(0.01, 0.88, "Tendencia-ciclo (media móvil 2x12)", transform=axes[1].transAxes,
fontSize=9, color="#555555", bbox=dict(facecolor="white", alpha=0.85, edgecolor="none"))
axes[2].plot(dec_mul.seasonal, color=AZUL, lw=1.2); axes[2].axhline(1, color="k", lw=0.8)
axes[2].set_ylabel("índice")
axes[2].text(0.01, 0.88, "Estacional (se repite idéntico cada año)", transform=axes[2].transAxes,
fontSize=9, color="#555555", bbox=dict(facecolor="white", alpha=0.85, edgecolor="none"))
axes[3].plot(dec_mul.resid, "o-", color=VERDE, lw=0.8, ms=3); axes[3].axhline(1, color="k", lw=0.8)
axes[3].axvspan(COVID_INI, COVID_FIN, color=GRIS, alpha=0.25); axes[3].set_ylabel("razón")
axes[3].text(0.01, 0.88, "Residuo (error)", transform=axes[3].transAxes, fontSize=9,
color="#555555", bbox=dict(facecolor="white", alpha=0.85, edgecolor="none"))
plt.tight_layout(); plt.show()

```

Figura 6. Descomposición multiplicativa (clásica, período 12)



```

# =====
# 4.3 Cuantificación de componentes
# =====
T, S, R = dec_mul.trend.dropna(), dec_mul.seasonal, dec_mul.resid.dropna()

# Índice estacional (idéntico cada año por construcción)
idx_est = S.groupby(S.index.month).first()
print("Índice estacional mensual:", dict(zip(idx_est.index, idx_est.round(3))))
print(f"Mes máximo: {idx_est.idxmax()} ({idx_est.max():.3f}) · mes mínimo: {idx_est.idxmin()} ({idx_est.min():.3f}) "
      f"· razón máx/mín = {idx_est.max() / idx_est.min():.2f}")

# Fuerza de tendencia y estacionalidad (Hyndman y Athanasopoulos, 2021), sobre logaritmos
# porque el esquema es multiplicativo: log(y) = log(T) + log(S) + log(R)

```

```

lT, lS, lR = np.log(T), np.log(S.loc[R.index]), np.log(R)
lT = lT.loc[R.index]
Ft = max(0, 1 - lR.var() / (lT + lR).var())
Fs = max(0, 1 - lR.var() / (lS + lR).var())
print(f"Fuerza de la tendencia      Ft = {Ft:.2f}")
print(f"Fuerza de la estacionalidad Fs = {Fs:.2f}")

# Tendencia: crecimiento por tramos
# (los extremos de la media móvil están contaminados cerca del shock: se eligen tramos prudentes)
for a, b in [("2015-07-01", "2018-01-01"), ("2018-01-01", "2019-06-01"),
            ("2019-06-01", "2020-09-01"), ("2020-09-01", "2022-06-01"), ("2022-06-01", "2023-06-01")]:
    print(f"Tendencia {a[:7]} -> {b[:7]}: {T[a]:.1f} -> {T[b]:.1f} GWh ({100 * (T[b] / T[a] - 1):+.1f}%)")
    crec_anual = 100 * ((T["2023-06-01"] / T["2015-07-01"]) ** (12 / ((T.index.get_loc(pd.Timestamp("2023-06-01")) - T.index.get_loc(pd.Timestamp("2015-07-01")))) - 1))
    print(f"Crecimiento medio anual de la tendencia (2015-07 a 2023-06): {crec_anual:.2f}%")

# Ciclo: movimientos de baja frecuencia de la tendencia respecto de su recta de largo plazo
t = np.arange(len(T)); b1, b0 = np.polyfit(t, np.log(T.values), 1)
ciclo = pd.Series(np.log(T.values) - (b0 + b1 * t), index=T.index) * 100
print(f"\nCiclo (desv. % de la tendencia respecto de su recta log-lineal): mín {ciclo.min():.1f}% "
      f"({ciclo.idxmin():%Y-%m}), máx {ciclo.max():.1f}% ({ciclo.idxmax():%Y-%m})")

# Error
print(f"\nResiduo: media {R.mean():.3f}, desv. estándar {R.std():.3f} (≈{100 * R.std():.1f}% del nivel)")
print("Mayores desvíos del residuo (razón):")
print(R.sub(1).abs().sort_values(ascending=False).head(8).round(3).to_string())

```

```

Índice estacional mensual: {1: 1.205, 2: 1.098, 3: 1.01, 4: 0.895, 5: 0.89, 6: 0.933, 7: 0.971, 8: 0.958, 9: 0.915, 10: 0.921, 11: 1.046, 12: 1.159}
Mes máximo: 1 (1.205) · mes mínimo: 5 (0.890) · razón máx/mín = 1.35
Fuerza de la tendencia      Ft = 0.75
Fuerza de la estacionalidad Fs = 0.90

```

```

Tendencia 2015-07 -> 2018-01: 90.9 -> 106.9 GWh (+17.6%)
Tendencia 2018-01 -> 2019-06: 106.9 -> 107.2 GWh (+0.3%)
Tendencia 2019-06 -> 2020-09: 107.2 -> 95.1 GWh (-11.4%)
Tendencia 2020-09 -> 2022-06: 95.1 -> 106.9 GWh (+12.5%)
Tendencia 2022-06 -> 2023-06: 106.9 -> 113.2 GWh (+5.9%)
Crecimiento medio anual de la tendencia (2015-07 a 2023-06): 2.81%

```

```

Ciclo (desv. % de la tendencia respecto de su recta log-lineal): mín -9.3% (2020-09), máx 5.6% (2018-01)

```

```

Residuo: media 1.000, desv. estándar 0.033 (≈3.3% del nivel)
Mayores desvíos del residuo (razón):

```

```

fecha
2020-05-01    0.144
2020-04-01    0.099
2020-06-01    0.096
2017-11-01    0.070
2020-02-01    0.063
2019-10-01    0.057
2018-09-01    0.052
2018-11-01    0.052

```

```

# =====
# 4.4 Ciclo y error: visualización
# =====
fig, axes = plt.subplots(1, 3, figsize=(13, 3.6))

```


```

axes[0].plot(ciclo, color=ROJO); axes[0].axhline(0, color="k", lw=0.8)
axes[0].axvspan(COVID_INI, COVID_FIN, color=GRIS, alpha=0.25)
axes[0].set_ylabel("% de la tendencia"); axes[0].set_title("Figura 7a. Ciclo (tendencia sin su
recta)")
axes[1].hist(R.sub(1) * 100, bins=20, color=VERDE, alpha=0.85)
axes[1].set_xlabel("residuo (% del nivel)"); axes[1].set_title("Figura 7b. Distribución del
residuo")
plot_acf(R.values, lags=24, ax=axes[2], zero=False, title="Figura 7c. ACF del residuo")
plt.tight_layout(); plt.show()

# Dispersión del residuo con y sin la ventana COVID
cov = (R.index >= COVID_INI) & (R.index <= COVID_FIN)
print(f"Desv. del residuo: con COVID {R.std():.4f} · sin COVID {R[~cov].std():.4f} · solo COVID
{R[cov].std():.4f}")
n_r = len(R); banda_r = 1.96 / np.sqrt(n_r)
ar = acf(R.values, nlags=24)
print(f"ACF del residuo: rezago 1 = {ar[1]:+.2f}, rezago 2 = {ar[2]:+.2f}, rezago 12 = {ar[12]:+.2f}
"
      f"(banda ±{banda_r:.2f})")

```

Desv. del residuo: con COVID 0.0325 · sin COVID 0.0254 · solo COVID 0.0472
ACF del residuo: rezago 1 = +0.44, rezago 2 = +0.20, rezago 12 = -0.01 (banda ±0.20)



Tendencia. La tendencia-ciclo (Figura 6, segundo panel) crece de 90,9 GWh (julio de 2015) a 106,9 GWh (enero de 2018), un +17,6 %; se estanca entre enero de 2018 y junio de 2019 (+0,3 %); cae un -11,4 % hasta septiembre de 2020 (95,1 GWh) por el shock COVID; se recupera un +12,5 % hasta junio de 2022 (106,9 GWh) y vuelve a crecer un +5,9 % hasta junio de 2023 (113,2 GWh). El crecimiento medio anual es de 2,8 %. Conviene advertir que la media móvil suaviza los quiebres: en los bordes del shock de 2020 el descenso aparece anticipado y gradual aunque el quiebre real fue abrupto, y se pierden seis observaciones en cada extremo.

Estacionalidad. El componente estacional es anual ($s = 12$), rígido por construcción (idéntico cada año) y muy intenso: el índice varía entre 0,890 (mayo) y 1,205 (enero), es decir, una razón máximo/mínimo de 1,35. Su fuerza, medida como $F_s = 1 - \text{Var}(R) / \text{Var}(S + R)$ sobre logaritmos (Hyndman y Athanasopoulos, 2021), es de **0,90**, frente a **0,75** de la tendencia (F_t): la estacionalidad es la estructura dominante.

Ciclo. Un ciclo es una fluctuación de baja frecuencia, no periódica con período fijo, distinta de la estacionalidad. En 9 años no se observa un ciclo recurrente: el único movimiento de baja frecuencia respecto de la recta de largo plazo de la tendencia es el **estancamiento de 2018-2019** (+5,6 % sobre la recta en enero de 2018) y el **hundimiento de 2020** (-9,3 % en septiembre de 2020, Figura 7a). Este último no es un ciclo económico, sino un **shock exógeno** (intervención), y 9 años no bastan para identificar un ciclo de negocio de 5 a 10

años. Por lo tanto, en este caso la clasificación correcta es *tendencia + estacionalidad + intervención*, con ciclo no identificable.

Error. El residuo tiene media 1,000 y desviación estándar de 0,033 (3,3 % del nivel), que baja a 2,5 % sin el periodo COVID y sube a 4,7 % dentro de él. Los mayores desvíos son abril, mayo y junio de 2020 (-9,9 %, -14,4 % y -9,6 %), el atípico de noviembre de 2017 (+7,0 %) y febrero de 2020 (+6,3 %). **El residuo no es ruido blanco:** su ACF tiene $\rho_1 = +0,44$ y $\rho_2 = +0,20$, por sobre la banda de $\pm 0,20$, y su histograma tiene una cola negativa, atribuible al shock.

Lectura de las Figuras 7a-7c. El ciclo estimado muestra la meseta previa al COVID y la depresión posterior. La distribución del residuo está concentrada en torno a 0 con cola izquierda (meses COVID). La autocorrelación positiva de orden 1 del residuo indica que la descomposición clásica no absorbió toda la estructura: el shock COVID, que persiste varios meses, no cabe en una estacionalidad fija ni en una media móvil suavizada.



Limitaciones del método. La descomposición clásica (i) supone estacionalidad constante, (ii) no es robusta a atípicos y a quiebres, y (iii) pierde datos en los extremos. STL permitiría una estacionalidad cambiante y un ajuste robusto, y será considerada en la fase de modelamiento.

5. Análisis de autocorrelación (ACF y PACF)

La ACF mide la correlación entre y_t e y_{t-k} , incluyendo efectos indirectos a través de los rezagos intermedios. La PACF mide la correlación entre y_t e y_{t-k} **descontando** el efecto de los rezagos $1, \dots, k-1$ (Box et al., 2015). Se calculan hasta el rezago 48 (cuatro ciclos estacionales) sobre la serie en nivel, con $n = 108$. La banda aproximada de significación al 95 % es $\pm 1,96/\sqrt{n} = \pm 0,189$ (las bandas de los gráficos de statsmodels, basadas en la fórmula de Bartlett, pueden ser algo más anchas en la ACF).

5.1 Correlogramas de la serie

```
# =====
# 5.1 ACF y PACF de la serie (nivel), 48 rezagos
# =====
NLAGS = 48
fig, axes = plt.subplots(1, 2, figsize=(13, 4))
plot_acf(y.values, lags=NLAGS, ax=axes[0], title="Figura 8a. ACF de consumo_gwh (48 rezagos)")
plot_pacf(y.values, lags=NLAGS, ax=axes[1], method="yw", title="Figura 8b. PACF de consumo_gwh (48 rezagos)")
for ax in axes:
    ax.set_xlabel("rezago (meses)")
    for k in (12, 24, 36, 48):
        ax.axvline(k, color=GRIS, ls=":", lw=0.8)
plt.tight_layout(); plt.show()
```



```
# =====
# 5.2 Valores y rezagos significativos (banda  $\pm 1.96/\sqrt{n}$ )
# =====
n = len(y); banda = 1.96 / np.sqrt(n)
r = acf(y.values, nlags=NLAYS)
p = pacf(y.values, nlags=NLAYS, method="yw")

clave = [1, 2, 3, 6, 9, 12, 13, 18, 24, 36, 48]
tabla = pd.DataFrame({"ACF": r[clave], "PACF": p[clave]}, index=pd.Index(clave,
name="rezago")).round(3)
tabla["ACF signif."] = np.abs(r[clave]) > banda
tabla["PACF signif."] = np.abs(p[clave]) > banda
display(tabla)

print(f"n = {n}; banda de confianza 95% =  $\pm\{banda:.3f\}$ ")
print("Rezagos ACF significativos :", [k for k in range(1, NLAYS + 1) if abs(r[k]) > banda])
print("Rezagos PACF significativos:", [k for k in range(1, NLAYS + 1) if abs(p[k]) > banda])
print("ACF en mltiplos de 12      :", {k: round(float(r[k]), 3) for k in (12, 24, 36, 48)})

n = 108; banda de confianza 95% =  $\pm 0.189$ 
Rezagos ACF significativos : [1, 2, 8, 11, 12, 13, 16, 17, 19, 20, 21, 23, 24, 25, 27, 28, 29, 30,
31, 32, 33, 35, 36, 37, 39, 40, 41, 43, 44, 47, 48]
Rezagos PACF significativos: [1, 2, 4, 6, 9, 10, 11, 13]
ACF en mltiplos de 12      : {12: 0.652, 24: 0.468, 36: 0.369, 48: 0.378}
```

	ACF	PACF	ACF signif.	PACF signif.
rezago				
1	0.745	0.745	True	True
2	0.345	-0.469	True	True
3	0.007	-0.061	False	False
6	-0.032	-0.235	False	True
9	-0.115	0.307	False	True
12	0.652	-0.087	True	False
13	0.459	-0.283	True	True
18	-0.179	0.095	False	False
24	0.468	-0.022	True	False
36	0.369	-0.011	True	False
48	0.378	0.178	True	False

5.2 Interpretación

Persistencia. La ACF parte en $\rho_1 = 0,745$ y $\rho_2 = 0,345$, ambos significativos, y cae a prácticamente cero en el rezago 3 ($\rho_3 = 0,007$). Dos meses consecutivos tienen consumos parecidos, en parte por la suavidad del ciclo estacional y en parte por la persistencia del nivel; en la serie desestacionalizada la autocorrelación de orden 1 sube a 0,87 (Figura 9a), lo que confirma una **fuerte persistencia del nivel** asociada a la tendencia y a los cambios de nivel: la media no es constante y la serie **no es estacionaria**.

Estacionalidad. Los rezagos 12, 24, 36 y 48 son significativos ($\rho_{12} = 0,652$; $\rho_{24} = 0,468$; $\rho_{36} = 0,369$; $\rho_{48} = 0,378$) y los rezagos adyacentes (11 y 13, este último con $\rho_{13} = 0,459$) también. La combinación de **picos en múltiplos de 12** con su **decaimiento lento** es la firma de una estacionalidad anual estable combinada con no estacionariedad estacional o de nivel: una estacionalidad puramente determinista en una serie estacionaria produciría picos que no se atenúan. Entre picos, la ACF oscila: es significativamente negativa en las vecindades de los semiciclos (rezagos 16-21, 27-33 y 39-44, con un mínimo de $-0,37$ en el rezago 32), pero en el rezago 6 es cercana a cero ($\rho_6 = -0,03$) en lugar de fuertemente negativa, lo que refleja la forma **no sinusoidal** del perfil (un máximo dominante en verano y un repunte menor en invierno, sección 3.3). El gran número de rezagos significativos (31 de 48) no indica dependencia en todos ellos: la ACF de una serie no estacionaria arrastra correlación espuria a muchos rezagos.

Dependencia directa (PACF). La PACF tiene dos valores grandes en los primeros rezagos ($\phi_{11} = 0,745$ y $\phi_{22} = -0,469$), y luego valores significativos dispersos en los rezagos 4, 6, 9, 10, 11 y 13, sin un pico en el rezago 12 ($-0,087$) ni en 24 o 36 ($-0,022$ y $-0,011$). Un primer valor positivo seguido de uno negativo es compatible con una dependencia de corto plazo de tipo autorregresivo de orden dos, pero esa lectura es **provisoria**: con una serie no estacionaria, la PACF mezcla la dependencia genuina con el efecto de la tendencia y de la estacionalidad, y la estructura significativa cerca del rezago 12 (9, 10, 11 y 13) indica que la información estacional se distribuye en torno al ciclo anual.

Qué no se puede concluir todavía. Este correlograma permite **diagnosticar** (no estacionariedad, estacionalidad anual) pero no **identificar** los órdenes (p, q) (P, Q) de un modelo, lo que corresponde después de estacionarizar la serie.

5.3 Contraste: serie desestacionalizada y residuo

```
# =====
# 5.3 Contraste: ¿qué ocurre con la ACF al retirar tendencia y estacionalidad?
# =====
# Serie desestacionalizada (y / índice estacional) y residuo de la descomposición
y_dsz = (y / dec_mul.seasonal).dropna()
fig, axes = plt.subplots(1, 2, figsize=(13, 3.6))
plot_acf(y_dsz.values, lags=36, ax=axes[0], zero=False, title="Figura 9a. ACF de la serie
desestacionalizada")
plot_acf(R.values, lags=36, ax=axes[1], zero=False, title="Figura 9b. ACF del residuo de la
descomposición")
for ax in axes: ax.set_xlabel("rezago (meses)")
plt.tight_layout(); plt.show()



rd = acf(y_dsz.values, nlags=36)
print("ACF desestacionalizada: rezago 1 =", round(rd[1], 2), "| rezago 12 =", round(rd[12], 2), "|
```

```

rezago 24 =", round(rd[24], 2))
ra = acf(R.values, nlags=36)
print("ACF del residuo      : rezago 1 =", round(ra[1], 2), "| rezago 12 =", round(ra[12], 2), "|
rezago 24 =", round(ra[24], 2))

```

ACF desestacionalizada: rezago 1 = 0.87 | rezago 12 = 0.15 | rezago 24 = -0.23
ACF del residuo : rezago 1 = 0.44 | rezago 12 = -0.01 | rezago 24 = -0.27



Lectura de las Figuras 9a y 9b. Al dividir por el índice estacional, los picos en 12, 24 y 36 desaparecen ($\rho_{12} = 0,15$ y $\rho_{24} = -0,23$): esto confirma que esas correlaciones en la serie original provienen de la estacionalidad. Lo que queda es una autocorrelación de orden 1 muy alta ($\rho_1 = 0,87$) y de decaimiento lento, que corresponde a la tendencia y al shock COVID (no estacionariedad en media). En el residuo de la descomposición se reduce a $\rho_1 = +0,44$ y $\rho_{12} = -0,01$: la estacionalidad fue bien capturada, pero queda dependencia de corto plazo (el efecto COVID y los cambios de nivel).

6. Interpretación técnica integrada

6.1 Convergencia de la evidencia

Componente	Gráficos exploratorios	Descomposición	ACF / PACF
Tendencia	Crecimiento 2015-2018, estancamiento 2018-2019, caída 2020, recuperación 2021-2023 (Figuras 1 y 4a)	Tendencia-ciclo de 90,9 a 113,2 GWh, +2,8 % anual; $F_t = 0,75$	ACF con decaimiento lento; $\rho_1 = 0,87$ en la serie desestacionalizada: media no constante
Estacionalidad	Perfil con máximo en enero (1,19) y mínimo en mayo (0,89); repunte invernal; explicada por la temperatura (Figuras 3a-3c)	Índice 0,890-1,205; $F_s = 0,90$, componente dominante	Picos significativos en 12, 24, 36 y 48 (0,65; 0,47; 0,37; 0,38) con decaimiento lento
Ciclo	Solo el estancamiento 2018-2019 y el hundimiento de 2020	Desviación de la tendencia de +5,6 % a -9,3 % respecto de su recta: no hay periodicidad	Sin señal de periodicidad distinta de 12

Componente	Gráficos exploratorios	Descomposición	ACF / PACF
Cambios de nivel y shocks	Quiebre en marzo de 2020 (mín. -24,4 %, 194,6 GWh perdidos); atípico de 2017; sin escalón visible en 2019 (Figuras 1 y 2)	Residuos extremos en 2020 y en 2017-11	Residuo con $\rho_1 = +0,44$: queda estructura sin explicar
Error	Variabilidad alrededor del nivel de ~ 10 GWh	Desviación del residuo de 3,3 % (2,5 % sin COVID)	Tras la descomposición desaparece el pico estacional ($\rho_{12} = -0,01$)

6.2 Conclusión técnica

La serie de consumo comercial de DEL es **no estacionaria en media, con estacionalidad anual intensa y estable, tendencia creciente con un estancamiento en 2018-2019, un shock exógeno de gran magnitud (COVID) y un atípico de medición confirmado**. Tres líneas de evidencia independientes coinciden en ello: los gráficos (perfil estacional repetido, media móvil no constante), la descomposición (estacionalidad con $F_s = 0,90$, tendencia con $F_t = 0,75$, residuo dominado por 2020) y la ACF (picos en múltiplos de 12 con decaimiento lento y ρ_1 de 0,87 en la serie desestacionalizada). La PACF no contradice este diagnóstico, pero no permite por sí sola identificar órdenes. La estacionalidad es, además, económicamente interpretable: está asociada al calor estival y, en menor medida, al frío invernal.

6.3 Implicancias para el modelamiento

1. **Transformación.** La evidencia sobre la forma de la estacionalidad es mixta; se recomienda partir con el logaritmo (esquema multiplicativo) y contrastarlo con Box-Cox y con la serie sin transformar en la Semana 2.
2. **Diferenciación.** La estacionalidad persistente (picos de ACF en 12, 24, 36 y 48 sin decaimiento rápido) sugiere una diferencia estacional $D = 1$; la persistencia del nivel ($\rho_1 = 0,87$ en la serie desestacionalizada) sugiere una diferencia regular $d = 1$. Ambas se decidirán con ADF, KPSS y el criterio de varianza para evitar sobre-diferenciar. La diferencia estacional debe calcularse con `serie.diff(12)` y no con `np.diff(x, n=12)`, que aplica doce diferencias regulares.
3. **Quiebre COVID.** Con diferenciación estacional, cada valor compara un mes con el mismo mes del año anterior; los valores que cruzan el borde del shock (marzo de 2020 a febrero de 2021 y enero a diciembre de 2022) quedan distorsionados: unas 24 de las 96 observaciones diferenciadas (25 %). Habrá que elegir entre modelar el shock con variables indicadoras (consume grados de libertad y exige suponer una forma funcional) o acotar la muestra (deja menos de tres ciclos estacionales completos).
4. **Atípico de 2017.** Tratarlo como faltante o con una indicadora antes de estimar.
5. **Covariables.** Se mantiene el enfoque univariado (SARIMA); la temperatura podría usarse en una extensión SARIMAX, con el costo de tener que proyectarla. Los días hábiles deben volver a examinarse sobre la serie desestacionalizada.
6. **Referencia de comparación.** Con $F_s = 0,90$, la estacionalidad es tan regular que el ingenuo estacional será una vara exigente, y el modelo deberá superarla para justificar su complejidad.

6.4 Limitaciones del análisis

La muestra de entrenamiento (nueve años, de los cuales dos están afectados por el shock) limita la precisión de las estimaciones estacionales y no permite identificar ciclos de baja frecuencia. El shock es un único episodio sin replicación, por lo que su magnitud contrafactual depende de un supuesto (nivel 2018-2019 constante). La descomposición clásica impone estacionalidad fija, no es robusta a atípicos y no separa la tendencia del shock. La elección aditivo/multiplicativo presenta evidencia mixta (elasticidad 0,31). Por último, los datos son sintéticos: las conclusiones sobre el mecanismo físico son hipótesis coherentes con el contexto, no hallazgos empíricos.

7. Conclusiones

1. La serie mensual de consumo comercial de DEL (2015-2023) combina tendencia, estacionalidad anual dominante, un shock COVID y un atípico de medición; no presenta un ciclo identificable.
2. La estacionalidad es la estructura más fuerte ($F_s = 0,90$): máximo en enero, mínimo en mayo y un repunte menor en julio, explicados por el calor estival y el frío invernal.
3. La tendencia crece alrededor de 2,8 % anual, con un estancamiento en 2018-2019 y una depresión en 2020; el COVID implicó unos 195 GWh no consumidos (8,4 % de lo esperado entre marzo de 2020 y diciembre de 2021).
4. La ACF con picos en los rezagos 12, 24, 36 y 48 y decaimiento lento confirma una serie no estacionaria con estacionalidad anual; la PACF sugiere dependencia de corto plazo, pero sus órdenes se identificarán solo después de estacionarizar.
5. El modelamiento debe incorporar transformación (logaritmo como punto de partida), diferenciación estacional y probablemente regular, y un tratamiento explícito del quiebre COVID y del atípico de 2017.

8. Referencias

- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). Wiley.
- Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3-73.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>
- Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92-96.
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437-450.
- Universidad Andrés Bello. (s. f.). *MCDI505 — Análisis de series de tiempo: Caso transversal del curso* [Material de curso]. UNAB Online.

9. Declaración de uso de herramientas de IA

Se utilizó un asistente de IA generativa (Claude, de Anthropic) para elaborar el borrador del código, los análisis y la redacción de este informe. El autor revisó el notebook, verificó que se ejecuta de principio a fin y es responsable de su contenido y de las decisiones metodológicas expuestas.